统计最优传输

Statistical Optimal Transport

第 1 章：最优传输

中文试译

Sinho Chewi

Jonathan Niles-Weed

Philippe Rigollet

原书：Springer，2025，Lecture Notes in Mathematics 2364.
本译稿范围：印刷页 1–36 / 原 PDF 物理页 15–50.
保留原文编号；参考文献仅摘录本章所引项目.
本章 DOI：10.1007/978-3-031-85160-5_1.
© 作者，2025；独家许可予 Springer Nature Switzerland AG.
本稿为学习用中文试译.
来源疑误按原文保留并另注，核验说明随稿提供.

2026 年 11 月 3 日

目录

第 1 章 最优传输 **1**

1.1 最优传输问题 1

1.1.1 Monge 问题与 Kantorovich 问题 1

1.1.2 耦合 2

1.1.3 离散最优传输 5

1.2 Wasserstein 距离 6

1.3 一维最优传输 11

1.4 Brenier 定理 13

1.4.1 凸函数的梯度 13

1.4.2 循环单调性 14

1.4.3 Brenier 定理的证明 17

1.5 Kantorovich 对偶 17

1.5.1 Kantorovich 对偶问题 18

1.5.2 半对偶 20

1.5.3 最优传输基本定理 21

1.5.4 改进的 Brenier 定理 23

1.6 $p = 1$ 时的对偶 25

1.7 讨论 27

1.8 习题 28

第 1 章

最优传输

1.1 最优传输问题

Monge 在其 1781 年的论文 [231] 中提出了如下问题：怎样把一堆给定的沙子搬运过去，填满一个给定的沟渠，并使搬运沙子的成本最小？这个问题可以用概率分布建模. 首先注意，要使这项任务能够完成，沙堆与沟渠必须具有相同的体积. 不失一般性，将这个体积归一化为 1. 由此，我们需要考虑 $\mathbb{R}^d$ 上的两个概率测度 μ 和 ν. 借助两个随机变量 $X \sim \mu$、$Y \sim \nu$ 来思考通常更方便. 它们就是这个约束优化问题的输入.

1.1.1 Monge 问题与 Kantorovich 问题

回到搬沙子的类比，搬运沙堆意味着寻找一个称为*传输映射*（transport map）的可测函数 $T : \mathbb{R}^d \to \mathbb{R}^d$，它规定位于 $x \in \mathbb{R}^d$ 的沙子应搬到 $T(x) \in \mathbb{R}^d$. 要让传输映射真正完成任务，即填满沟渠，就必须保证只要 $X \sim \mu$，便有 $T(X) \sim \nu$. 此时称 T 将 μ *推前*至 ν，或者称 ν 是 μ 经由 T 得到的*推前测度*（pushforward measure），记为 $T_{\#}\mu = \nu$. 这就是我们的约束.

现在来看目标函数. 回顾 Monge 的问题，我们要使搬运沙子的成本最小. 成本可以用许多方式衡量，例如体力消耗或燃料消耗等. 为简化叙述，这里仅用沙子移动的欧氏距离来衡量. 位于 x 的沙子移动的距离为 $\|T(x) - x\|$. 因而，平均移动距离为

$$\int \|T(x) - x\| \, \mu(dx).$$

因此，最优传输问题（optimal transport problem）的 Monge 表述，是在 T 将 μ 推前至 ν 的约束下，使上述目标最小化：

$$\inf_{T:T_{\#}\mu=\nu} \int \|T(x) - x\| \, \mu(dx).$$

注意，传输成本还有许多其他选择. 最一般地，通常考虑一般成本 $c(X, T(X))$，其中 $c(x, y)$ 衡量把 $x \in \mathbb{R}^d$ 搬到 $y \in \mathbb{R}^d$ 的成本. 在这一一般框架下，甚至可以允许 X 和 Y 定义在两个不同的空间上，而不必都是 $\mathbb{R}^d$. 本讲义主要关注 $c(x, y) = \|x - T(x)\|$ 或 $c(x, y) = \|x - T(x)\|^2$ 的情形，它们导出 Wasserstein 距离（Wasserstein distance）. 空间 $\mathbb{R}^d$ 也可以换成更复杂的空间，例如黎曼流形，但这通常超出了本讲义的范围（原书第 5.6 节除外）.

虽然 Monge 问题很容易表述，但仍有几个问题需要回答：

- 这样的有效传输映射是否总是存在？反过来说，约束集合是否可能为空？
- 如果存在极小化解，它是否唯一？如何刻画它？注意，我们的约束不是凸的，因此这个问题相当难以回答.

一个简单的例子便能回答第一个问题. 取 $d = 1$，设 $\mu = \delta_0$ 是位于 0 的点质量，而 $\nu = \frac{1}{2}\delta_{-1} + \frac{1}{2}\delta_1$ 是两个点质量的混合. 无论怎样选择传输映射 T，推前测度 $T_{\#}\mu$ 都是位于 $T(0)$ 的点质量 $\delta_{T(0)}$，因此根本无法完成传输，至少确定性映射做不到.

直观地，我们希望有

$$T(0) = \begin{cases} -1, & \text{以概率} \frac{1}{2}, \\ 1, & \text{以概率} \frac{1}{2}, \end{cases} \qquad \text{且} \qquad T(x) = x, \quad \forall x \neq 0.$$

这样的 T 不是函数，而是一个 Markov 核（Markov kernel）：它为每个点 $x \in \mathbb{R}$ 指定一个概率分布.

第二个问题在此后近两个世纪中一直没有令人满意的答案，直到苏联数学家 Leonid Kantorovich 在一篇具有开创性的两页论文 [173] 中引入了该问题的一个松弛形式，恰好允许使用上例所讨论的 Markov 核. 等价地，这种表述涉及的是耦合，而不是映射.

设 μ, ν 是 $\mathbb{R}^d$ 上的两个概率测度，γ 是这两个分布的一个耦合 (coupling)，即 $\mathbb{R}^d \times \mathbb{R}^d$ 上的一个联合分布，其第一边缘分布为 μ，第二边缘分布为 ν：对于任意 Borel 集 $A \in \mathbb{R}^d$，有

$$\gamma(A \times \mathbb{R}^d) = \mu(A) \qquad \text{且} \qquad \gamma(\mathbb{R}^d \times A) = \nu(A).$$

之所以使用“耦合”一词，是因为原本 $X \sim \mu$ 与 $Y \sim \nu$ 是互不相关的两个随机变量，而耦合通过描述它们的概率依赖关系，使它们处在同一个概率空间上. 本讲义以下始终用 $\Gamma_{\mu,\nu}$ 表示 μ 和 ν 的所有耦合组成的集合.

设 $c : \mathbb{R}^d \times \mathbb{R}^d \to [0, \infty)$ 是可测成本函数. 最优传输问题的一般 Kantorovich 表述就是下面的优化问题：

$$\inf_{\gamma \in \Gamma_{\mu,\nu}} \int c(x, y)\, \gamma(dx, dy). \tag{KOT}$$

1.1.2 耦合

为了更好地理解 Kantorovich 问题，考察集合 $\Gamma_{\mu,\nu}$ 很有帮助.

也许最简单的耦合是独立耦合 (independent coupling) $\gamma = \mu \otimes \nu$，这里仅假设 $X \sim \mu$ 与 $Y \sim \nu$ 相互独立：对于任意 Borel 集 $A, B \subseteq \mathbb{R}^d$，

$$\gamma(A \times B) = \mu(A) \cdot \nu(B).$$

下一个命题汇集了关于 $\Gamma_{\mu,\nu}$ 的一些初步事实.

命题 1.1. 设 μ,ν 是 $\mathbb{R}^d$ 上的两个概率测度. 两者的耦合集合 $\Gamma_{\mu,\nu}$ 非空、凸，并且在弱收敛拓扑下是紧的.

证明. 由于独立耦合总是存在，所以 $\Gamma_{\mu,\nu}\neq\varnothing$.

为证明 $\Gamma_{\mu,\nu}$ 是凸的，考虑两个耦合 $\gamma_0,\gamma_1\in\Gamma_{\mu,\nu}$，对任意 $\lambda\in(0,1)$ 定义混合 $\gamma_\lambda=(1-\lambda)\gamma_0+\lambda\gamma_1$. 注意，对于任意 Borel 集 $A\in\mathbb{R}^d$，

$$\begin{aligned}\gamma_\lambda(A\times\mathbb{R}^d)&=(1-\lambda)\gamma_0(A\times\mathbb{R}^d)+\lambda\gamma_1(A\times\mathbb{R}^d)\\&=(1-\lambda)\mu(A)+\lambda\mu(A)=\mu(A).\end{aligned}$$

因此 γ_λ 的第一边缘分布为 μ，同理，其第二边缘分布为 ν. 所以任意 $\lambda\in(0,1)$ 都有 $\gamma_\lambda\in\Gamma_{\mu,\nu}$，从而 $\Gamma_{\mu,\nu}$ 是凸的.

为完成这个命题的证明，我们证明 $\Gamma_{\mu,\nu}$ 是紧的. 根据 Prokhorov 定理（原书定理 B.3），只需证明 $\Gamma_{\mu,\nu}$ 是闭的且（一致）紧的测度族. 为此，回顾 Prokhorov 定理可知，常值序列 $(\mu)_n$、$(\nu)_n$ 都是紧的，因而对任意 $\varepsilon>0$，存在紧集 $K\subset\mathbb{R}^d$ 使 $\mu(K^c)+\nu(K^c)<\varepsilon$. 于是 $K\times K$ 也是紧集，且对任意 $\gamma\in\Gamma_{\mu,\nu}$，

$$\begin{aligned}\gamma\big((K\times K)^c\big)&\le\gamma(\mathbb{R}^d\times K^c)+\gamma(K^c\times\mathbb{R}^d)\\&=\mu(K^c)+\nu(K^c)<\varepsilon.\end{aligned}$$

因此 $\Gamma_{\mu,\nu}$ 是紧的测度族. 此外，$\gamma\in\Gamma_{\mu,\nu}$ 等价于：对所有有界连续函数 $f:\mathbb{R}^d\to\mathbb{R}$，

$$\int f(x)\,\gamma(dx,dy)=\int f\,d\mu\qquad\text{且}\qquad\int f(y)\,\gamma(dx,dy)=\int f\,d\nu.$$

由弱收敛的定义（原书定理 B.4）可知 $\Gamma_{\mu,\nu}$ 是闭的. 因此，Prokhorov 定理表明 $\Gamma_{\mu,\nu}$ 是紧的. □

耦合 $\gamma\in\Gamma_{\mu,\nu}$ 刻画两个随机变量 $X\sim\mu$ 与 $Y\sim\nu$ 之间的依赖关系. 如上所述，一种选择是假设 X 与 Y 独立，由此得到独立耦合. 在图 1.1（左）中，我们绘出了两个高斯混合分布之间的独立耦合. 作为独立耦合的另一个极端，举例来说，设 $X\sim\mathcal{N}(0,1)$、$Y\sim\chi^2_1$，注意 Y 与 X^2 同分布. 因此可以采用满足 $Y=X^2$ 的确定性耦合（deterministic coupling）：

$$\gamma(dx,dy)=\mu(dx)\,\delta_{x^2}(dy).$$

我们在图 1.1（右）中绘出了这个耦合；注意它是退化的.

继续考察耦合，假设 $X\sim\mathcal{N}(0,1)$、$Y\sim\mathcal{N}(0,1)$，则可以采用任意满足下式的耦合：

$$\begin{pmatrix}X\\Y\end{pmatrix}\sim\mathcal{N}\left(\begin{pmatrix}0\\0\end{pmatrix},\begin{pmatrix}1&\rho\\\rho&1\end{pmatrix}\right),\tag{1.1}$$

其中 $\rho\in[-1,1]$ 是 X 与 Y 的相关系数，见图 1.2.

本章后面的 Brenier 定理表明，在温和的正则条件下，二次成本 Kantorovich 问题的解由一个确定性耦合达到. 正如下文将讨论的，当 μ 和 ν 是离散测度时，可以通过考察集合 $\Gamma_{\mu,\nu}$ 的几何来理解这一事实.

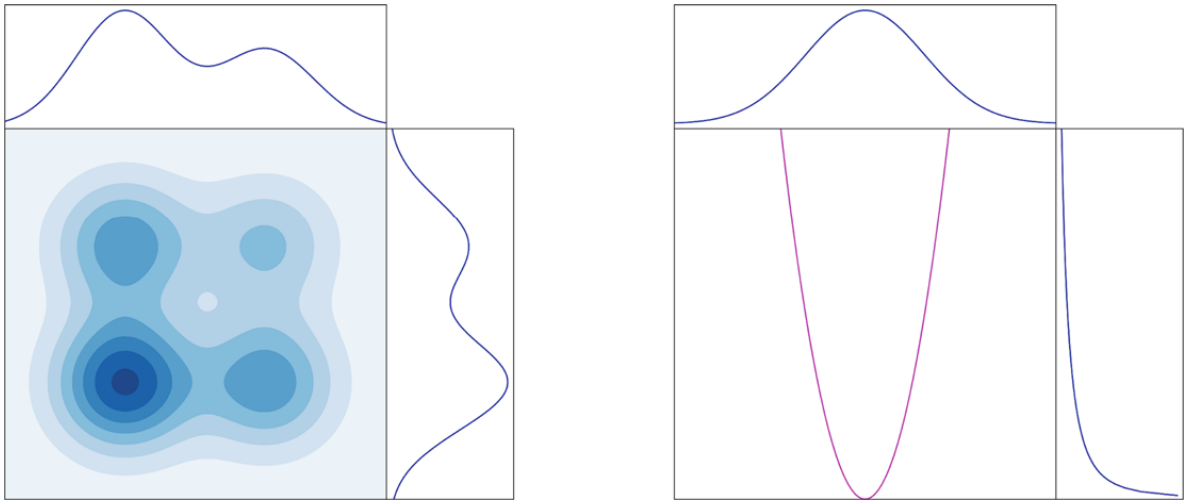


图 1.1: （左）两个高斯分布的混合分布之独立耦合.（右）$X \sim \mathcal{N}(0,1)$ 与 $Y \sim \chi_1^2$ 的确定性耦合.

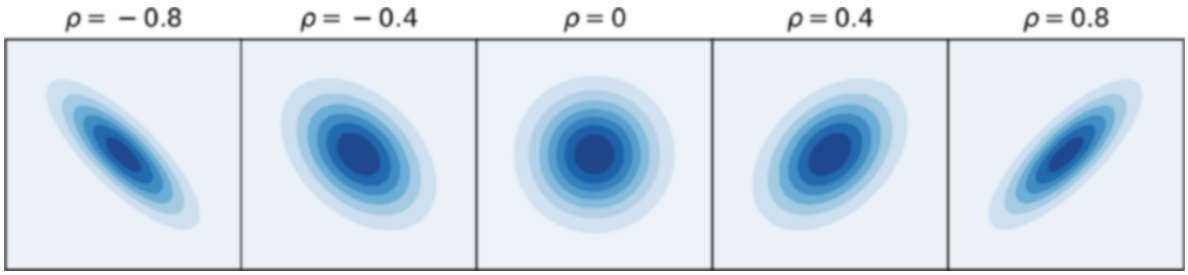


图 1.2: ρ 取五个不同值时，(1.1) 所示的二元高斯耦合.

1.1.3 离散最优传输

μ 和 ν 为两个离散分布的情形，在实践中尤其重要. 例如，μ, ν 可以是点云上的经验测度. 考虑

$$\mu = \sum_{i=1}^{m} p_i \delta_{x_i}, \qquad \text{且} \qquad \nu = \sum_{j=1}^{n} q_j \delta_{y_j}.$$

此时，$X \sim \mu$ 与 $Y \sim \nu$ 的耦合 γ 可由非负矩阵 $P \in \mathbb{R}^{m \times n}$ 刻画，其中 $P_{i,j} = \gamma(X = x_i, Y = y_j)$. $\gamma \in \Gamma_{\mu,\nu}$ 的边缘约束直接转化为

$$\forall i \in [m], \quad \sum_{j \in [n]} P_{i,j} = p_i, \qquad \text{且} \qquad \forall j \in [n], \quad \sum_{i \in [m]} P_{i,j} = q_j.$$

分别用 $\mathbf{1}_m$、$\mathbf{1}_n$ 表示长度为 m、n 的全一向量，这些约束就可简洁地表示为 $P\mathbf{1}_n = p$、$P^\mathsf{T}\mathbf{1}_m = q$，其中 $p = (p_1, \ldots, p_n)^\mathsf{T}$、$q = (q_1, \ldots, q_m)^\mathsf{T}$.

与耦合类似，成本 c 也可以由一个 $m \times n$ 矩阵 C 表示，其中 $C_{i,j} = c(x_i, y_j)$，$i \in [m]$、$j \in [n]$. 因此 Kantorovich 最优传输问题 (KOT) 等价于

$$\min_{P \in \mathbb{R}_+^{m \times n}} \sum_{i,j \in [n]} C_{i,j} P_{i,j} \qquad \text{满足} \qquad P\mathbf{1}_n = p, \quad P^\mathsf{T}\mathbf{1}_m = q,$$

也可以更简洁地写为

$$\min_{P \in \mathbb{R}_+^{m \times n}} \langle C, P \rangle \qquad \text{满足} \qquad P\mathbf{1}_n = p, \quad P^\mathsf{T}\mathbf{1}_m = q,$$

其中 $\langle C, P \rangle = \operatorname{tr}(C^\mathsf{T} P)$ 是实 $m \times n$ 矩阵空间上的 Frobenius 内积.

特别地，当 $m = n$，并且所有权重 p_i、q_j 均为 $1/n$ 时，有效耦合矩阵 P 的集合就是双随机矩阵集合的一个倍数，后者也称为 Birkhoff 多面体（Birkhoff polytope）：

$$\operatorname{Birk} := \{\gamma \in \mathbb{R}_+^{n \times n} : \gamma \mathbf{1}_n = \mathbf{1}_n, \ \mathbf{1}_n^\mathsf{T} \gamma = \mathbf{1}_n^\mathsf{T}\}. \tag{1.2}$$

此时，(KOT) 化为

$$\min_{P \in n^{-1} \operatorname{Birk}} \langle C, P \rangle. \tag{1.3}$$

Birkhoff 多面体的极点是置换矩阵：它们是二元矩阵 $\pi \in \{0,1\}^{n \times n}$，每行每列恰有一个非零元素. 特别地，根据凸几何的一般原理，形如 (1.3) 的任意线性规划都可以取一个形如 $n^{-1}\pi$ 的矩阵作为解. 这种形式的传输方案由一个确定性映射（即置换）诱导，因此此时 Monge 问题有解. 正如后续各节将展示的，更一般地，$\Gamma_{\mu,\nu}$ 的极点在最优传输问题的几何中扮演着特殊角色.

1.2 Wasserstein 距离

Kantorovich 问题 (KOT) 对许多不同的成本函数都有意义，而每种情形都有不同的解释. 例如，一个自然的例子是取平凡度量 $c(x,y) = \mathbb{1}_{x\neq y}$. 此时 (KOT) 给出

$$\inf_{\gamma\in\Gamma_{\mu,\nu}} \gamma(X \neq Y),$$

这是全变差距离（total variation distance）的一个熟知表述，见习题 9. 然而，注意平凡距离 $\mathbb{1}_{x\neq y}$ 与 $\mathbb{R}^d$ 的几何无关. 特别地，它只区分 x 与 y 是否不同，而不说明两者相距多远. 全变差也表现出这一局限. 事实上，若 $\mu = \delta_x$、$\nu = \delta_y$，则只要 $x \neq y$，(KOT) 的目标值就等于 1.

要从 Kantorovich 问题得到一个具有几何意义的量，就必须选择能反映 x 与 y 之间实际距离的成本. 这个想法导出了 Wasserstein 距离. 对任意 $p \geq 1$，用 $\mathcal{P}_p(\mathbb{R}^d)$ 表示配备欧氏范数 $\|\cdot\|$ 的 $\mathbb{R}^d$ 上所有具有有限 p 阶矩的概率测度组成的集合：

$$\mu \in \mathcal{P}_p(\mathbb{R}^d) \quad\Longleftrightarrow\quad \int \|x\|^p \,\mu(dx) < \infty.$$

两个概率测度 $\mu,\nu \in \mathcal{P}_p(\mathbb{R}^d)$ 之间的 p-Wasserstein 距离定义为

$$W_p(\mu,\nu) = \inf_{\gamma\in\Gamma_{\mu,\nu}} \left(\int \|x-y\|^p \,\gamma(dx,dy)\right)^{1/p},$$

其中回顾一下，$\Gamma_{\mu,\nu}$ 是 μ 与 ν 的耦合集合.

首先证明，上述下确界实际上能够达到. 为此，定义

$$I(\gamma) := \int \|x-y\|^p \,\gamma(dx,dy),$$

注意根据定义，存在 $\Gamma_{\mu,\nu}$ 中的序列 $(\gamma_n)_n$，使 $I(\gamma_n) \to W_p^p(\mu,\nu)$. 由于 $\Gamma_{\mu,\nu}$ 是紧的（命题 1.1），$(\gamma_n)_n$ 有一个子序列收敛到某个 $\bar\gamma \in \Gamma_{\mu,\nu}$. 根据定义，$W_p(\mu,\nu) \leq I(\bar\gamma)$. 由于 $(x,y) \mapsto \|x-y\|^p$ 无界，I 并不连续，但它是下半连续的，因此 $I(\bar\gamma) \leq \liminf_{n\to\infty} I(\gamma_n) = W_p^p(\mu,\nu)$（portmanteau 定理的第三条，原书定理 B.4）. 从而 $I(\bar\gamma) = W_p^p(\mu,\nu)$. 注意，这个证明中关于成本函数所用的唯一性质就是下半连续性，因此该论证很容易推广到更一般的成本.

由此，可以采用如下 Wasserstein 距离的定义. 注意，这些距离实际上应该称为 Kantorovich–Rubinstein 距离，不过我们仍沿用当下的“Wasserstein 化”潮流.

定义 1.2. *两个概率测度 $\mu,\nu \in \mathcal{P}_p(\mathbb{R}^d)$ 之间的 p-Wasserstein 距离定义为*

$$W_p(\mu,\nu) = \min_{\gamma\in\Gamma_{\mu,\nu}} \left(\int \|x-y\|^p \,\gamma(dx,dy)\right)^{1/p}.$$

命题 1.3. *p-Wasserstein 距离在 $\mathcal{P}_p(\mathbb{R}^d)$ 上定义了一个度量，即对任意 $\mu,\nu\in\mathcal{P}_p(\mathbb{R}^d)$：*

1. $W_p(\mu,\nu)\geq 0$.
2. $W_p(\mu,\nu)=W_p(\nu,\mu)$.
3. $W_p(\mu,\nu)=0$ 当且仅当 $\mu=\nu$.
4. 对任意 $\rho\in\mathcal{P}_p(\mathbb{R}^d)$，$W_p(\mu,\nu)\leq W_p(\mu,\rho)+W_p(\rho,\nu)$.

证明. 首先注意，第 1 条和第 2 条显然成立.

现在证明第 3 条. 若 $\mu=\nu$，则测度 $\gamma(dx,dy)=\mu(dx)\delta_x(dy)$ 是有效耦合，即 $\gamma\in\Gamma_{\mu,\nu}$. 具体地，$\gamma$ 是 $X\sim\mu$ 时 (X,X) 的分布. 因此

$$0\leq W_p^p(\mu,\mu)\leq\int\|x-y\|^p\,\gamma(dx,dy)=\int\|x-x\|^p\,\mu(dx)=0.$$

为证明第 3 条的反方向，注意若 $W_p(\mu,\nu)=0$，则存在 $\bar{\gamma}\in\Gamma_{\mu,\nu}$，使 $(X,Y)\sim\bar{\gamma}$ 且 $X=Y$ 几乎必然成立；特别地，它们必然同分布，即 $\mu=\nu$.

为完成证明，检验第 4 条的三角不等式. 为此使用粘合引理（gluing lemma，原书引理 B.5），它保证存在 X,Y,Z，满足 $X\sim\mu$、$Y\sim\nu$、$Z\sim\rho$，并且 (X,Z) 与 (Z,Y) 都是最优耦合. 于是

$$\begin{aligned}W_p(\mu,\nu)&\leq\big(\mathbb{E}\|X-Y\|^p\big)^{1/p}\\&=\big(\mathbb{E}\|X-Z+Z-Y\|^p\big)^{1/p}\\&\leq\big(\mathbb{E}\|X-Z\|^p\big)^{1/p}+\big(\mathbb{E}\|Z-Y\|^p\big)^{1/p}\\&=W_p(\mu,\rho)+W_p(\rho,\nu),\end{aligned}$$

其中第一行使用了耦合 (X,Y) 的次优性，第三行使用了 L^p 范数的三角不等式，最后一行使用了耦合 (X,Z) 与 (Z,Y) 的最优性. □

例 1.4 (简单情形下的 Wasserstein 距离).

1. 固定 $x,y\in\mathbb{R}^d$，则

$$W_p(\delta_x,\delta_y)=\|x-y\|.$$

因此，$(\mathbb{R}^d,\|\cdot\|)$ 通过 $x\mapsto\delta_x$ 等距嵌入 $(\mathcal{P}_p(\mathbb{R}^d),W_p)$.

2. 固定 $x,y\in\mathbb{R}^d$ 及 $0\leq\lambda,\tau\leq 1$，则

$$W_p\big(\lambda\delta_x+(1-\lambda)\delta_y,\tau\delta_x+(1-\tau)\delta_y\big)=|\lambda-\tau|^{1/p}\|x-y\|.$$

注意，由 L^p 范数的序关系可知，只要 $p\leq q$，就有 $W_p(\mu,\nu)\leq W_q(\mu,\nu)$. 特别地，Wasserstein 距离中最小的是 W_1.

Wasserstein 距离在随机变量上诱导了一种有用的拓扑：它们使紧空间上的弱收敛度量化；相关背景见原书附录 B. 更具体地，序列 $(\mu_n)_n$ 满足 $W_p(\mu_n,\mu)\to 0$，当且仅当它弱收敛于 μ（记为 $\mu_n \rightsquigarrow \mu$），并且 p 阶矩收敛，即 $\int \|\cdot\|^p\, d\mu_n \to \int \|\cdot\|^p\, d\mu$. 这种“度量化”性质可以在最优传输的所有主要教材中找到，也常被用来论证使用 Wasserstein 距离而不是其他距离的合理性. 然而，这几乎算不上一个能将它与其他距离区分开的特征：许多其他距离，例如 Lévy–Prokhorov 距离、Fortet–Mourier 距离等，也具有这一性质，见 [317, 第 6 章]. 实际上，这个广为人知的结果并没有充分揭示对于某个 ε，$W_p(\mu,\nu)\le\varepsilon$ 所具有的定量含义.

例如，下面的命题说明，如果两个尾部足够轻的随机变量在任意 $p>1$ 的 p-Wasserstein 距离下接近，那么它们的所有矩也一定接近. 我们通过考虑次指数随机变量（sub-exponential random variable），来形式化尾部轻这一假设；这里指满足下式的随机变量 Z：

$$\mathbb{E}e^{|Z|}\le 2. \tag{1.4}$$

对于这样的随机变量，有如下界.

命题 1.5. *设 $X\sim\mu$ 和 $Y\sim\nu$ 是两个次指数随机变量. 则对于任意 $p>1$，存在常数 $C_p>0$，使任意整数 $\ell\ge 1$ 都满足*

$$\big|\mathbb{E}|X|^\ell-\mathbb{E}|Y|^\ell\big|\le (C_p\ell)^\ell W_p(\mu,\nu).$$

证明. 由函数 $x\mapsto|x|^\ell$（$\ell\ge1$）的凸性，

$$|X|^\ell-|Y|^\ell\le \ell|X-Y|\big(|X|^{\ell-1}\vee|Y|^{\ell-1}\big).$$

对两边取期望，并应用 Hölder 不等式，得到对任意耦合 (X,Y)，

$$\big|\mathbb{E}|X|^\ell-\mathbb{E}|Y|^\ell\big|\le \ell\big(\mathbb{E}|X-Y|^p\big)^{1/p}\big(\mathbb{E}(|X|^{\ell-1}\vee|Y|^{\ell-1})^q\big)^{1/q},\qquad \frac1p+\frac1q=1.$$

取 X 与 Y 的最优耦合，得到

$$\big|\mathbb{E}|X|^\ell-\mathbb{E}|Y|^\ell\big|\le \ell W_p(\mu,\nu)\big(\mathbb{E}(|X|^{\ell-1}\vee|Y|^{\ell-1})^q\big)^{1/q}.$$

最后，回顾次指数随机变量的一个标准性质 [314]：若 Z 是次指数的，则对所有 $k\ge1$，$\big(\mathbb{E}[|Z|^k]\big)^{1/k}\le k$. 因此

$$\big(\mathbb{E}(|X|^{\ell-1}\vee|Y|^{\ell-1})^q\big)^{\frac{1}{(\ell-1)q}}\le 2(\ell-1)q\le 2\frac{\ell p}{p-1}.$$

□

上述结果令人鼓舞：若得到两个测度之间 Wasserstein 距离的界，就能得到它们的矩之间距离的定量界. 不过，相较于其他常用距离或散度，例如全变差或 Kullback–Leibler 散度，Wasserstein 距离也可能往往相当大；关于这些距离的列表、彼此比较及其与统计问题的关系，见 [302, 第 2 章].

然而，Wasserstein 距离通常可以由其他常用距离控制. 例如，下面的结果表明，在有界区域上，Wasserstein 距离受全变差距离控制（背景见习题 9）. 此外，它的证明首次展示了如何给出 Wasserstein 距离的界：只需构造一个（次优的）耦合 γ，使 $\mathbb{E}_\gamma\|X-Y\|^p$ 得到适当控制即可.

定理 1.6. *设 $\mu,\nu\in\mathcal{P}_p(\mathbb{R}^d)$ 是两个分布，其密度分别为 f 和 g. 则对任意 $p\geq 1$，*

$$W_p^p(\mu,\nu)\leq 2^{p-1}\inf_{x_0\in\mathbb{R}^d}\int\|x-x_0\|^p|f(x)-g(x)|\,dx.$$

特别地，若 μ 和 ν 的支撑都包含在同一个直径为 D 的球内，则

$$W_p^p(\mu,\nu)\leq D^p d_{\mathrm{TV}}(\mu,\nu),$$

其中 $d_{\mathrm{TV}}(\mu,\nu)$ 是 μ 与 ν 之间的全变差距离，定义为

$$d_{\mathrm{TV}}(\mu,\nu)=\frac{1}{2}\int|f(x)-g(x)|\,dx.$$

证明. 假设 $\mu\neq\nu$，否则结论显然成立. 正如定理陈述前所提到的，我们将构造 μ 与 ν 的一个显式耦合. 为此，考虑三个正函数 $(f-g)_+$、$(f-g)_-$ 与 $f\wedge g$（参见图 1.3），并注意

$$\int\big((f-g)_+-(f-g)_-\big)=\int f-\int g=1-1=0,$$

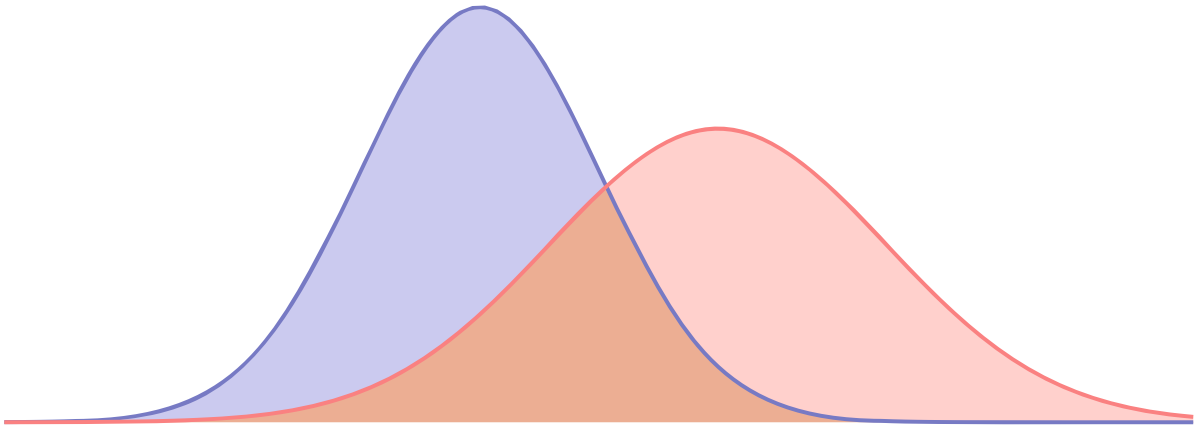


图 1.3: 积分 $\int(f-g)_+$、$\int(f-g)_-$ 与 $\int f\wedge g$ 分别对应蓝色、红色与橙色区域.

因此

$$\int (f-g)_+ = \int (f-g)_- =: t > 0,$$

并且

$$\int f \wedge g = \frac{1}{2}\left(\int f + \int g - \int (f-g)_+ - \int (f-g)_-\right) = 1 - t.$$

接着，将这些函数归一化，得到三个密度

$$h_+ = \frac{1}{t}(f-g)_+, \qquad h_- = \frac{1}{t}(f-g)_-, \qquad h_\wedge = \frac{1}{1-t} f \wedge g.$$

可以将 f 与 g 重新写成上述密度的混合：

$$f = t h_+ + (1-t) h_\wedge, \qquad g = t h_- + (1-t) h_\wedge.$$

再令 Z_+、Z_-、$Z_\wedge$ 是三个相互独立的随机变量，其密度分别为 h_+、h_-、$h_\wedge$；令 B 是参数为 $t \in (0,1]$ 的 Bernoulli 随机变量，且与 Z_+、Z_-、$Z_\wedge$ 独立.

现在可以定义 μ 与 ν 的耦合了. 为此，令随机变量对 (X,Y) 满足

$$\begin{aligned} X &= B Z_+ + (1-B) Z_\wedge, \\ Y &= B Z_- + (1-B) Z_\wedge, \end{aligned}$$

注意 (X,Y) 的分布 γ 确实是 μ 与 ν 的有效耦合. 结合这一事实与不等式 $\|x-y\|^p \le 2^{p-1}\big(\|x-x_0\|^p + \|y-x_0\|^p\big)$，得到

$$\begin{aligned} W_p^p(\mu,\nu) &\le \mathbb{E}_\gamma \|X-Y\|^p \\ &= \mathbb{P}(B=0)\cdot 0 + \mathbb{P}(B=1) \int \|x-y\|^p h_+(x) h_-(y)\, dx\, dy \\ &\le t 2^{p-1} \left(\int \|x-x_0\|^p h_+(x)\, dx + \int \|y-x_0\|^p h_-(y)\, dy \right) \\ &= t 2^{p-1} \left(\int \|x-x_0\|^p \big(h_+(x) + h_-(x)\big)\, dx \right) \\ &= 2^{p-1} \left(\int \|x-x_0\|^p \big((f-g)_+(x) + (f-g)_-(x)\big)\, dx \right) \\ &= 2^{p-1} \left(\int \|x-x_0\|^p |f(x) - g(x)|\, dx \right). \end{aligned}$$

再对右端关于 x_0 取最小值，即得结论. 第二个结论只需取 x_0 为上述球的球心，便容易得到. □

μ 和 ν 绝对连续的假设是多余的；只要直接操作测度而不是密度，完全相同的证明仍然适用，只是记号会稍显晦涩；见 [317, 定理 6.15].

1.3 一维最优传输

为了对最优传输获得一些直观认识，我们考察一个较简单的情形：μ 和 ν 是实数轴上的概率测度. 在这种情形下，可以定义它们各自的累积分布函数.

回顾一下，随机变量 Z 的*累积分布函数*（cumulative distribution function，CDF）是函数 $F:\mathbb{R}\to[0,1]$，其定义为

$$F(t):=\mathbb{P}(Z\le t),\qquad t\in\mathbb{R}.$$

由于 F 单调不减，可以定义其*伪逆*（pseudo-inverse）$F^\dagger$：

$$F^\dagger(u)=\inf\{t\in\mathbb{R}:F(t)\ge u\},\qquad u\in[0,1],$$

其中约定 $\inf\varnothing=\infty$. 虽然 $F^\dagger$ 并非真正的逆函数，但它确实满足下述性质：

$$F^\dagger(u)\le t\quad\Longleftrightarrow\quad u\le F(t). \tag{1.5}$$

这一性质常用于模拟随机变量. 设 $U\sim\mathrm{Unif}([0,1])$ 是均匀随机变量，则 $Z\sim F^\dagger(U)$ 的累积分布函数为 F. 事实上，对任意 $t\in\mathbb{R}$，

$$\mathbb{P}(Z\le t)=\mathbb{P}(F^\dagger(U)\le t)=\mathbb{P}(U\le F(t))=F(t). \tag{1.6}$$

下面的定理利用累积分布函数刻画一维最优传输.

定理 1.7. *设 $\mu,\nu\in\mathcal{P}_1(\mathbb{R})$ 是两个概率分布，其累积分布函数分别为 F_μ 和 F_ν. 设 $U\sim\mathrm{Unif}([0,1])$ 是均匀随机变量，以 $\bar\gamma$ 表示 $(F_\mu^\dagger(U),F_\nu^\dagger(U))$ 的分布. 那么 $\bar\gamma\in\Gamma_{\mu,\nu}$ 是 μ 与 ν 的一个有效耦合，并且它是最优的：*

$$W_1(\mu,\nu)=\int|x-y|\,\bar\gamma(\mathrm{d}x,\mathrm{d}y)=\min_{\gamma\in\Gamma_{\mu,\nu}}\int|x-y|\,\gamma(\mathrm{d}x,\mathrm{d}y).$$

此外，

$$W_1(\mu,\nu)=\int_{-\infty}^{\infty}|F_\mu(t)-F_\nu(t)|\,\mathrm{d}t.$$

证明. 由 (1.6) 可知 $\bar\gamma\in\Gamma_{\mu,\nu}$，只需再验证其最优性. 为此，注意到对任意 $\gamma\in\Gamma_{\mu,\nu}$，若

$(X,Y)\sim\gamma$，则由 Fubini 定理可得

$$\begin{aligned}
&\int |x-y|\,\gamma(\mathrm{d}x,\mathrm{d}y)\\
&=\iint_{-\infty}^{\infty}(\mathbb{1}_{x\le t<y}+\mathbb{1}_{y\le t<x})\,\mathrm{d}t\,\gamma(\mathrm{d}x,\mathrm{d}y)\\
&=\int_{-\infty}^{\infty}\big(\gamma(X\le t<Y)+\gamma(Y\le t<X)\big)\,\mathrm{d}t\\
&=\int_{-\infty}^{\infty}\big(\gamma(X\le t)+\gamma(Y\le t)-2\gamma(X\le t,Y\le t)\big)\,\mathrm{d}t\\
&\ge\int_{-\infty}^{\infty}\big(F_\mu(t)+F_\nu(t)-2(F_\mu(t)\wedge F_\nu(t))\big)\,\mathrm{d}t\\
&=\int_{-\infty}^{\infty}|F_\mu(t)-F_\nu(t)|\,\mathrm{d}t.
\end{aligned}$$

为了说明当 $\gamma=\bar\gamma$ 时，上述不等式成为等式，注意到

$$\begin{aligned}
\bar\gamma(X\le t,Y\le t)&=\mathbb{P}(F_\mu^\dagger(U)\le t,F_\nu^\dagger(U)\le t)\\
&=\mathbb{P}(U\le F_\mu(t),U\le F_\nu(t))\\
&=\mathbb{P}(U\le F_\mu(t)\wedge F_\nu(t))\\
&=F_\mu(t)\wedge F_\nu(t).
\end{aligned}$$

我们已经证明

$$\int |x-y|\,\gamma(\mathrm{d}x,\mathrm{d}y)\ge\int_{-\infty}^{\infty}|F_\mu(t)-F_\nu(t)|\,\mathrm{d}t=\int|x-y|\,\bar\gamma(\mathrm{d}x,\mathrm{d}y),$$

因而 $\bar\gamma$ 是最优耦合. □

如果 Z 存在密度，那么它的累积分布函数 F 实际上是 $F^\dagger$ 的左逆，即 $F\circ F^\dagger=\mathrm{Id}$. 如果 μ 存在密度，这一事实意味着最优耦合 $\bar\gamma$ 具有下述特殊形式：若 $X\sim\mu$，则

$$(X,F_\nu^\dagger\circ F_\mu(X))\sim\bar\gamma. \tag{1.7}$$

换言之，Monge 问题与 Kantorovich 问题的解相同，因为我们找到了一个传输映射 $\bar T=F_\nu^{-1}\circ F_\mu$，使得 $\bar T_\#\mu=\nu$，并且

$$\begin{aligned}
\int|x-\bar T(x)|\,\mu(\mathrm{d}x)&=\min_{\gamma\in\Gamma_{\mu,\nu}}\int|x-y|\,\gamma(\mathrm{d}x,\mathrm{d}y)\\
&=\min_{T:T_\#\mu=\nu}\int|x-T(x)|\,\mu(\mathrm{d}x).
\end{aligned}$$

虽然本节着重讨论 W_1 距离，但 (1.7) 给出的耦合 $\bar\gamma$ 实际上具有普遍最优性：对于任意严格凸成本的 Kantorovich 问题，它都是最优的；这里的严格凸成本指形如 $c(x,y)=h(x-y)$ 的成本，其中 $h:\mathbb{R}\to\mathbb{R}$ 严格凸. 这包括所有 $p>1$ 的 W_p 距离. 参见习题 8.

注意，$\bar{T}$ 是两个递增函数的复合，因此也是单调递增函数. 一维的连续单调递增函数是凸函数的导数，这提示我们，可以通过考虑凸函数的梯度，将这一性质推广到高维. 高维中这种单调传输映射的存在性，正是 Brenier 的重要结果 [55] 的内容. 下面我们就来研究这一结果.

1.4 Brenier 定理

对任意 $p \geq 1$，p-Wasserstein 距离都是一个自然的研究对象. 不过，$p = 1, 2$ 两种情形具有突出的特殊结构，后文的大部分讨论将围绕它们展开. 我们先研究 $p = 2$ 的情形；这一情形尤为显著的一点，是它与凸分析的密切联系.

回顾一下，

$$W_2^2(\mu, \nu) = \min_{\gamma \in \Gamma_{\mu,\nu}} \int \|x - y\|^2 \, \gamma(\mathrm{d}x, \mathrm{d}y). \tag{W_2^2}$$

定理 1.8 (Brenier)**.** *设 $\mu, \nu \in \mathcal{P}_2(\mathbb{R}^d)$ 是两个概率测度，μ 存在密度，并设 $X \sim \mu$. 如果 $\bar{\gamma}$ 是 (W_2^2) 的一个最优耦合，即*

$$\int \|x - y\|^2 \, \bar{\gamma}(\mathrm{d}x, \mathrm{d}y) = \min_{\gamma \in \Gamma_{\mu,\nu}} \int \|x - y\|^2 \, \gamma(\mathrm{d}x, \mathrm{d}y) = W_2^2(\mu, \nu),$$

那么存在凸函数 $\varphi : \mathbb{R}^d \to \mathbb{R}$，使得 $(X, \nabla\varphi(X)) \sim \bar{\gamma} \in \Gamma_{\mu,\nu}$.

Brenier 定理的关键假设是 μ 存在密度，即 μ 关于 Lebesgue 测度绝对连续. 特别地，由于凸函数在 Lebesgue 几乎处处可微，这一假设保证了 $\nabla\varphi(X)$ 是有意义的.

在开始证明之前，我们先考虑 Brenier 定理在统计学上的一个推论.Brenier 定理断言，只要 μ 存在密度，那么对任意 $\nu \in \mathcal{P}_2(\mathbb{R}^d)$，都存在凸函数 ϕ，使得 $\nabla\phi_{\#}\mu = \nu$. 由于凸函数的梯度是单调函数在高维的自然对应物，因此该定理大幅推广了节 1.3 提到的经典一维事实：若 $U \sim \mathrm{Unif}([0, 1])$，则 $F_\nu^\dagger(U) \sim \nu$.

在一维情形中，函数 $F_\nu^\dagger$ 称为 ν 的分位数函数（quantile function），在统计学中具有基础性意义. 因此，可以利用 Brenier 定理定义多元分位数的概念 [75, 160]. 事实证明，这一观点成果丰硕，并催生了广泛的统计应用 [159].（更多细节见节 1.7.）

回到 Brenier 定理本身，目前还看不出最优传输为何会与凸函数的梯度相关. 因此，我们先研究这类梯度，以建立直观认识.

1.4.1 凸函数的梯度

首先注意，对连续函数 $f : \mathbb{R} \to \mathbb{R}$，存在某个可微凸函数 φ 使得 $f = \varphi'$，当且仅当 f 单调不减. 事实上，φ 的凸性意味着，对任意 $x, y \in \mathbb{R}$，

$$\varphi(x) - \varphi(y) \leq (x - y)\varphi'(x), \tag{1.8}$$

$$\varphi(y) - \varphi(x) \leq (y - x)\varphi'(y). \tag{1.9}$$

将上述两个不等式相加，得到

$$(x-y)(\varphi'(x)-\varphi'(y))\geq 0,$$

所以 φ' 单调不减.

对于 $\mathbb{R}^d$ 上的函数，这一结论是否有对应的推广？当然，我们立即得到，对任意 $x,y\in\mathbb{R}^d$,

$$\langle x-y,\widetilde{\nabla}\varphi(x)-\widetilde{\nabla}\varphi(y)\rangle\geq 0,$$

其中 $\widetilde{\nabla}\varphi(x)\in\partial\varphi(x)$ 表示 φ 在 x 处的一个次梯度 (subgradient；凸分析的预备知识见附录 A) . 遗憾的是，虽然在一维情形中，两点不等式 (1.8) 和 (1.9) 能够推出任意点配置所对应的不等式，但在高维中不再如此，因此我们需要刻画更多信息.

实际上，凸性还蕴含许多这样的不等式：任取整数 $k\geq 2$ 以及一组点 $x_1,\dots,x_k\in\mathbb{R}^d$，有

$$\begin{aligned}\varphi(x_i)-\varphi(x_{i+1})&\leq\langle x_i-x_{i+1},\widetilde{\nabla}\varphi(x_i)\rangle,\quad i=1,\dots,k-1,\\ \varphi(x_k)-\varphi(x_1)&\leq\langle x_k-x_1,\widetilde{\nabla}\varphi(x_k)\rangle.\end{aligned}$$

将这些不等式相加，得到

$$\sum_{i=1}^{k}\langle x_i-x_{i+1},\widetilde{\nabla}\varphi(x_i)\rangle\geq 0,\tag{1.10}$$

其中约定 $x_{k+1}=x_1$.[1]

1.4.2 循环单调性

由于 φ 在 x 处的次微分中可能含有多个点，在将 $\widetilde{\nabla}\varphi(\cdot)$ 视为从 $\mathbb{R}^d$ 到 $\mathbb{R}^d$ 的映射之前，我们先描述其图像 $\{(x,\widetilde{\nabla}\varphi(x)):x\in\mathbb{R}^d\}$. 首先定义这类图像的一个重要性质.

定义 1.9. 若集合 $A\subset\mathbb{R}^d\times\mathbb{R}^d$ 满足：对任意整数 $k\geq 2$ 和任意点 $(x_i,y_i)\in A, i=1,\dots,k$，有

$$\sum_{i=1}^{k}\langle x_i-x_{i+1},y_i\rangle\geq 0,\tag{1.11}$$

其中约定 $x_{k+1}=x_1$，则称 A 是循环单调的 (*cyclically monotone*) .

由 (1.10) 可知，只要 φ 是凸的，集合 $\partial\varphi\subset\mathbb{R}^d\times\mathbb{R}^d$ 就是循环单调的. 事实上，$\mathbb{R}^d\times\mathbb{R}^d$ 的所有循环单调子集都具有这一形式.

定理 1.10 (Rockafellar)**.** 集合 $A\subset\mathbb{R}^d\times\mathbb{R}^d$ 是循环单调的，当且仅当存在闭凸函数 $\varphi:\mathbb{R}^d\to\mathbb{R}\cup\{\infty\}$，使得

$$A\subseteq\partial\varphi.$$

[1] 采用这一约定后，点 $x_1\to x_2\to\cdots\to x_k\to x_1$ 形成一个“循环”.

这一凸分析经典定理的证明见附录 A.

注意，条件 (1.11) 等价于要求：对任意点 $(x_i, y_i) \in A$，$i = 1, \dots, k$，有

$$\sum_{i=1}^{k} \|x_i - y_i\|^2 \le \sum_{i=1}^{k} \|x_{i+1} - y_i\|^2. \tag{1.12}$$

这一表述使我们能够看出它与最优传输的联系. 事实上，为了说明这一点，我们考虑下面的例子. 设

$$\mu = \frac{1}{n}\sum_{j=1}^{n} \delta_{a_j}, \qquad \nu = \frac{1}{n}\sum_{j=1}^{n} \delta_{b_j}.$$

在这一离散情形中，μ 与 ν 之间的全体耦合构成的集合可以与 Birkhoff 多面体等同起来 (见节 1.1.3)，其极点是经缩放的置换矩阵. 由于离散最优传输问题是一个线性规划，因而可在极点中取到解. 因此，我们只需考虑由置换给出的耦合. 具体而言，$\{1, \dots, n\}$ 的一个置换 σ 对应于耦合

$$\gamma = \frac{1}{n}\sum_{j=1}^{n} \delta_{(a_j, b_{\sigma(j)})}.$$

如果这样的耦合在所有置换中具有最小成本，即

$$\sum_{j=1}^{n} \|a_j - b_{\sigma(j)}\|^2 \le \sum_{j=1}^{n} \|a_j - b_{\tau(j)}\|^2, \qquad \forall \tau, \tag{1.13}$$

那么它就是最优耦合.

这一条件恰好等价于 γ 的支集具有循环单调性. 事实上，对 ν 的原子重新编号后，不妨假设 σ 为恒等置换. 于是，γ 的支集由点对 (a_j, b_j)，$j \in \{1, \dots, n\}$，组成. 给定任意由 k 个不同点组成的子集 $(x_i, y_i) = (a_{j_i}, b_{j_i}) \in \operatorname{supp}(\gamma)$，$i = 1, \dots, k$，令 τ 为 $\{j_1, \dots, j_k\}$ 上的循环置换，并保持其他指标不变：

$$\tau(j) = \begin{cases} j_{i-1}, & \text{若} j = j_i,\ i \in \{2, \dots, k\}, \\ j_k, & \text{若} j = j_1, \\ j, & \text{其他情形.} \end{cases}$$

那么 (1.13) 就蕴含 (1.12). 事实上，由于任意置换 τ 都可以分解为循环，类似的推理也表明，(1.12) 是 (1.13) 成立的充分条件.

前面的讨论说明，在离散情形中，最优耦合的支集是循环单调的. 在一般情形中也有类似的现象；不过，当 γ 不给其支集中的点赋予正质量时，上述论证就不成立了. 尽管如此，下面的结果表明，通过对小邻域 (例如球) 而非单个点进行推理，类似的策略仍可奏效. 我们需要小心处理，以保证能够在这些邻域上修改 γ，同时保持约束 $\gamma \in \Gamma_{\mu,\nu}$.

命题 1.11. 设 $\bar{\gamma} \in \Gamma_{\mu,\nu}$ 是 μ 与 ν 之间的最优耦合，即

$$\int \|x-y\|^2 \bar{\gamma}(\mathrm{d}x, \mathrm{d}y) = \min_{\gamma \in \Gamma_{\mu,\nu}} \int \|x-y\|^2 \gamma(\mathrm{d}x, \mathrm{d}y) = W_2^2(\mu,\nu).$$

那么 $\mathrm{supp}(\bar{\gamma})$ 是循环单调的.

证明. 假设 $S := \mathrm{supp}(\bar{\gamma})$ 不是循环单调的. 那么存在 $k \geq 2$ 和 $(x_i, y_i) \in S$，$i = 1, \ldots, k$，使得

$$\sum_{i=1}^{k} \|x_i - y_i\|^2 > \sum_{i=1}^{k} \|x_{i+1} - y_i\|^2.$$

由欧几里得范数的连续性，对 $i = 1, \ldots, k$，分别存在 x_i, y_i 的邻域 U_i, V_i，使得 $\bar{\gamma}(U_i \times V_i) > 0$，并且对所有 $\tilde{x}_i, \tilde{x}_i' \in U_i$、$\tilde{y}_i, \tilde{y}_i' \in V_i$，$i = 1, \ldots, k$，均有

$$\sum_{i=1}^{k} \|\tilde{x}_i - \tilde{y}_i\|^2 > \sum_{i=1}^{k} \|\tilde{x}_{i+1}' - \tilde{y}_i'\|^2. \tag{1.14}$$

现在令 γ_i，$i = 1, \ldots, k$，为 $\mathbb{R}^d \times \mathbb{R}^d$ 上的一族（条件）概率分布，定义为：对任意 Borel 集 $A \subset \mathbb{R}^d \times \mathbb{R}^d$，有 $\gamma_i(A) = \bar{\gamma}(A \mid U_i \times V_i)$. 接着，以 $\gamma_i^{(1)}$ 和 $\gamma_i^{(2)}$ 分别表示 γ_i 的第一和第二边缘分布，并定义混合：

$$\gamma = \bar{\gamma} + \frac{c}{k} \sum_{i=1}^{k} \big(\gamma_{i+1}^{(1)} \otimes \gamma_i^{(2)} - \gamma_i \big),$$

其中 $c > 0$ 稍后选定，并约定 $\gamma_{k+1} = \gamma_1$.

注意，对任意 Borel 集 $A \subset \mathbb{R}^d \times \mathbb{R}^d$，

$$\begin{aligned}
\gamma(A) &\geq \bar{\gamma}(A) - \frac{c}{k} \sum_{i=1}^{k} \gamma_i(A) \\
&= \bar{\gamma}(A) - \frac{c}{k} \sum_{i=1}^{k} \bar{\gamma}(A \mid U_i \times V_i) \\
&= \bar{\gamma}(A) - \frac{c}{k} \sum_{i=1}^{k} \frac{\bar{\gamma}(A \cap (U_i \times V_i))}{\bar{\gamma}(U_i \times V_i)} \\
&\geq \bar{\gamma}(A) - \frac{c\bar{\gamma}(A)}{k} \sum_{i=1}^{k} \frac{1}{\bar{\gamma}(U_i \times V_i)}.
\end{aligned}$$

所以，只要 $c < \min_{i \in [k]} \bar{\gamma}(U_i \times V_i)$，就有 $\gamma(A) \geq 0$. 此外，$\gamma(\mathbb{R}^d \times \mathbb{R}^d) = 1$，因此 γ 的确是 $\mathbb{R}^d \times \mathbb{R}^d$ 上的概率分布.

为了验证 $\gamma \in \Gamma_{\mu,\nu}$，注意到对任意 Borel 集 $B \subset \mathbb{R}^d$，

$$\begin{aligned}\gamma(B \times \mathbb{R}^d) &= \mu(B) + \frac{c}{k}\sum_{i=1}^{k}\big(\gamma_{i+1}^{(1)}(B) - \gamma_i(B \times \mathbb{R}^d)\big) \\ &= \mu(B) + \frac{c}{k}\sum_{i=1}^{k}\big(\gamma_{i+1}^{(1)}(B) - \gamma_i^{(1)}(B)\big) \\ &= \mu(B) + \frac{c}{k}\big(\gamma_{k+1}^{(1)}(B) - \gamma_1^{(1)}(B)\big) = \mu(B).\end{aligned}$$

同理，

$$\begin{aligned}\gamma(\mathbb{R}^d \times B) &= \nu(B) + \frac{c}{k}\sum_{i=1}^{k}\big(\gamma_i^{(2)}(B) - \gamma_i(\mathbb{R}^d \times B)\big) \\ &= \nu(B) + \frac{c}{k}\sum_{i=1}^{k}\big(\gamma_i^{(2)}(B) - \gamma_i^{(2)}(B)\big) = \nu(B).\end{aligned}$$

接着注意到，由 (1.14)，

$$\begin{aligned}&\int \|x-y\|^2\,\gamma(\mathrm{d}x,\mathrm{d}y) - \int \|x-y\|^2\,\bar{\gamma}(\mathrm{d}x,\mathrm{d}y) \\ &= \frac{c}{k}\sum_{i=1}^{k}\left(\begin{array}{r}\displaystyle\int_{U_{i+1}\times V_i} \|x-y\|^2\,\gamma_{i+1}^{(1)}(\mathrm{d}x)\,\gamma_i^{(2)}(\mathrm{d}y) \\ \displaystyle - \int_{U_i\times V_i} \|x-y\|^2\,\gamma_i(\mathrm{d}x,\mathrm{d}y)\end{array}\right) \\ &< 0.\end{aligned}$$

这与 $\bar{\gamma}$ 的最优性矛盾. □

1.4.3 Brenier 定理的证明

现在我们可以证明 Brenier 定理了.

定理 1.8的证明. 设 $\bar{\gamma}$ 是一个最优耦合. 由命题 1.11，$\mathrm{supp}(\bar{\gamma})$ 是循环单调的. 由 Rockafellar 的定理 1.10，可知存在凸函数 $\varphi : \mathbb{R}^d \to \mathbb{R} \cup \{\infty\}$，使得 $\bar{\gamma}(Y \in \partial\varphi(X)) = 1$. 但是，由于 φ 是凸函数，它在定义域的内部局部 Lipschitz 连续，而定义域的边界由凸性可知是零测集. 因此，由 Rademacher 定理，φ 在其定义域上关于 Lebesgue 测度几乎处处可微. 由于 μ 存在密度，这意味着 φ 在 μ 几乎处处可微. 因此，$\bar{\gamma}(Y = \nabla\varphi(X)) = 1$，或者换言之，若 $X \sim \mu$，则 $(X, \nabla\varphi(X)) \sim \bar{\gamma}$. □

1.5 Kantorovich 对偶

Brenier 定理表明，若 μ 有密度，则问题 (W_2^2) 的最优耦合是由某个凸函数 φ 的梯度给出的确定性耦合. 这一结果引出了如下问题：能否通过求解一个优化问题来直接找

到 φ，或者能否验证某个凸函数 φ 对应于一个最优耦合？利用凸对偶（convex duality）的工具可以回答这些问题.

在完全离散的情形（见节 1.1.3），(W_2^2) 是一个线性规划（linear program，LP），即目标函数和约束均为线性的；线性规划具有实用的对偶理论. 这一直觉也适用于一般情形，而且可以通过逼近论证使二者的联系严格化，见 [123, 第 11 章]. 事实上，Kantorovich 正是通过最优传输引入了线性规划对偶；自其诞生以来，这一理论一直在推动算法的发展.

1.5.1 Kantorovich 对偶问题

(W_2^2) 的对偶问题是一个最大化问题. 为了求出它的表达式，将约束 $\gamma \in \Gamma_{\mu,\nu}$ 编码为

$$\sup_{f,g\in C_b}\left\{\int f(x)\,\mu(dx)+\int g(y)\,\nu(dy)-\int\big(f(x)+g(y)\big)\,\gamma(dx,dy)\right\}$$
$$=\begin{cases}0, & \text{若}\gamma\in\Gamma_{\mu,\nu},\\ \infty, & \text{其他情形},\end{cases}$$

其中上确界取遍 $\mathbb{R}^d$ 上所有连续有界函数组成的集合 C_b. 因而，(W_2^2) 等价于

$$\inf_{\gamma\in\mathcal{M}_+}\left\{\int\|x-y\|^2\,\gamma(dx,dy)\right.$$
$$\left.+\sup_{f,g\in C_b}\left\{\int f(x)\,\mu(dx)+\int g(y)\,\nu(dy)-\int\big(f(x)+g(y)\big)\,\gamma(dx,dy)\right\}\right\},$$

其中下确界取遍 $\mathbb{R}^d\times\mathbb{R}^d$ 上所有正测度组成的集合 $\mathcal{M}_+$，不再施加其他限制. 注意，当 $\gamma\notin\Gamma_{\mu,\nu}$ 时，这个新目标函数为无穷大，因此两个问题严格等价.

接下来交换 inf 与 sup，得到 (W_2^2) 的最优值的如下下界：

$$\sup_{f,g\in C_b}\left\{\int f(x)\,\mu(dx)+\int g(y)\,\nu(dy)\right.$$
$$\left.+\inf_{\gamma\in\mathcal{M}_+}\left\{\int\big(\|x-y\|^2-f(x)-g(y)\big)\,\gamma(dx,dy)\right\}\right\}. \tag{1.15}$$

现在注意到，由于 γ 是正测度，

$$\inf_{\gamma\in\mathcal{M}_+}\left\{\int\big(\|x-y\|^2-f(x)-g(y)\big)\,\gamma(dx,dy)\right\}$$
$$=\begin{cases}0, & \text{若}f(x)+g(y)\le\|x-y\|^2,\quad\forall x,y\in\mathbb{R}^d,\\ -\infty, & \text{其他情形}.\end{cases}$$

的确，若存在一对 (x,y) 违反上述约束，则可以取测度序列 $\gamma_n = n\delta_{(x,y)}$，使该积分趋于 $-\infty$.

因此，我们已经证明 (W_2^2) 的一个下界为

$$\sup_{\substack{f,g\in C_b\\ f(x)+g(y)\le\|x-y\|^2}} \left\{\int f\,d\mu + \int g(y)\,d\nu\right\}.$$

虽然上面选择 $f,g\in C_b$ 是考虑到概率测度集合上的弱拓扑，但只要一对可积函数 (f,g) 几乎处处满足 $f(x)+g(y)\le\|x-y\|^2$，它们就给出 $W_2^2(\mu,\nu)$ 的这个下界.

引理 1.12. 设 $\mu,\nu\in\mathcal{P}_2(\mathbb{R}^d)$，则

$$\begin{aligned} W_2^2(\mu,\nu) &= \inf_{\gamma\in\Gamma_{\mu,\nu}} \int \|x-y\|^2\,\gamma(dx,dy)\\ &\ge \sup_{\substack{f\in L^1(\mu),\ g\in L^1(\nu)\\ f(x)+g(y)\le\|x-y\|^2}} \left\{\int f\,d\mu + \int g\,d\nu\right\}. \end{aligned}$$

证明. 设 $f\in L^1(\mu)$、$g\in L^1(\nu)$，使得对 μ 几乎处处的 x、ν 几乎处处的 y，有 $f(x)+g(y)\le\|x-y\|^2$，并固定 $\gamma\in\Gamma_{\mu,\nu}$. 那么

$$\begin{aligned} \int f(x)\,\mu(dx) + \int g(y)\,\nu(dy) &= \int \big(f(x)+g(y)\big)\,\gamma(dx,dy)\\ &\le \int \|x-y\|^2\,\gamma(dx,dy). \end{aligned}$$

对左侧取上确界，对右侧取下确界，即得结论. □

Kantorovich 对偶问题为

$$\sup_{\substack{f\in L^1(\mu),\ g\in L^1(\nu)\\ f(x)+g(y)\le\|x-y\|^2}} \left\{\int f\,d\mu + \int g\,d\nu\right\}. \tag{D-W_2^2}$$

它是原问题（primal problem）(W_2^2) 的对偶问题.

具体而言，引理 1.12 描述了一种称为弱对偶（weak duality）的现象，即只证明对偶问题给出了原问题的一个下界. 与之相对的是强对偶（strong duality）：不等式成为等式，原问题与对偶问题的目标函数取得相同的最优值. 严格说来，强对偶只涉及目标函数值，但原问题与对偶问题的解往往也存在联系；关于凸优化中的对偶理论，见 [52, 第 5 章].

我们将在节 1.5.3中证明，强对偶确实成立，并且它对我们关心的问题具有重要推论.

1.5.2 半对偶

在讨论强对偶之前，先稍作准备，定义半对偶问题（semidual problem）. 它是将对偶问题 (D-W_2^2) 部分求解后得到的版本，在最优传输映射的估计中起着重要作用（原书第 3 章）.

考虑 (D-W_2^2)，假设固定第一个对偶势 f；给定这个 f 后，应如何最优地选择 g? 由于对偶问题要求取上确界，我们希望使 g 尽可能大，但必须满足约束 $f(x)+g(y) \le \|x-y\|^2$. 因此，最优函数 g 为

$$g(y) = \inf_{x\in\mathbb{R}^d} \{\|x-y\|^2 - f(x)\}. \tag{1.16}$$

(1.16) 定义的函数称为 f 关于代价 $c(x,y) = \|x-y\|^2$ 的 c-共轭（c-conjugate）或 c-变换（c-transform），记为 f^c. 由此可以将对偶问题改写为

$$(\text{D-}W_2^2) = \sup_{f\in L^1(\mu)} \left\{ \int f\,d\mu + \int f^c\,d\nu \right\}. \tag{1.17}$$

这是半对偶问题的一种形式. 只需将(1.16) 中的 $\|x-y\|^2$ 换成 $c(x,y)$，它就适用于任意代价函数 c 的最优传输问题.

不过，对于二次代价，还可以再进一步，显式地建立半对偶与凸分析之间的联系. 此时半对偶为

$$\inf_{\phi\in L^1(\mu)} \left\{ \int \phi\,d\mu + \int \phi^*\,d\nu \right\}, \tag{SD}$$

其中 ϕ^* 表示 ϕ 的凸共轭（convex conjugate）；见原书附录 A.

命题 1.13. *设 $\mu,\nu \in \mathcal{P}_2(\mathbb{R}^d)$ 为概率测度. 那么，对偶问题 (D-W_2^2) 与半对偶问题 (SD) 在如下意义下等价：*

1. *目标函数值：分别用 S 和 D 表示 (SD) 与 (D-W_2^2) 的最优目标函数值，则*
$$\mathrm{D} = \int \|\cdot\|^2\,d\mu + \int \|\cdot\|^2\,d\nu - 2\cdot \mathrm{S}.$$
2. *解：一对函数 (f,g) 是 (D-W_2^2) 的最优解，当且仅当 $f = \|\cdot\|^2 - 2\varphi$ 且 $g = \|\cdot\|^2 - 2\varphi^*$，其中 φ 是 (SD) 的最优解.*

证明. 写成 $f = \|\cdot\|^2 - 2\phi$ 与 $g = \|\cdot\|^2 - 2\psi$；这只是对对偶势作重新参数化. 于是

$$\begin{aligned}\int f\,d\mu + \int g\,d\nu = &\int \|\cdot\|^2\,d\mu + \int \|\cdot\|^2\,d\nu \\ &- 2\left(\int \phi\,d\mu + \int \psi\,d\nu\right).\end{aligned}$$

约束 $f(x)+g(y) \le \|x-y\|^2$ 可改写为

$$\begin{aligned}&\|x\|^2 - 2\phi(x) + \|y\|^2 - 2\psi(y) \le \|x-y\|^2 \\ \iff\ &\phi(x)+\psi(y) \ge \langle x,y\rangle.\end{aligned}$$

因此，(D-W_2^2) 等价于

$$\inf_{\substack{\phi\in L^1(\mu),\ \psi\in L^1(\nu)\\ \phi(x)+\psi(y)\geq\langle x,y\rangle}}\left\{\int\phi\,d\mu+\int\psi\,d\nu\right\}.$$

接着应用上面同样的技巧：固定 ϕ 后，满足约束的最优 ψ 为

$$\psi(y)=\sup_{x\in\mathbb{R}^d}\{\langle x,y\rangle-\phi(x)\},$$

这恰好是凸共轭 ϕ^* 的定义. 代入即可得到上述等价关系. □

在前面的证明中，我们说明了固定 ϕ_0 后，最优的 ψ 为 $\psi=\phi_0^*$. 由问题的对称性，固定 $\psi=\phi_0^*$ 后，最优的 ϕ 又是 $\psi^*=\phi_0^{**}$. 我们可以设想反复进行这一过程，不断得到更好的对偶势，但实际上到这里过程便停止了. 因为 ϕ_0^* 是闭凸函数，所以它是自对偶的，从而 $\phi_0^{***}=\phi_0^*$；见原书附录 A. 这一论证最终表明，(SD) 中的最优势 φ 可以取为闭凸函数.

至此，我们已经在最优传输问题中遇到了两种凸函数 φ. 从原问题的角度看，Brenier 定理 1.8 表明最优传输计划支撑在某个凸函数的次微分上. 从对偶问题的角度看，(SD) 的极小化解可以取为凸函数. 下一小节将说明，这两个凸函数其实是同一个函数.

1.5.3 最优传输基本定理

回顾 Brenier 定理：若测度 μ 有密度，则 μ 与 ν 之间任一最优耦合都支撑在某个凸函数的梯度的图像上. 事实上，逆命题也成立：任何支撑在某个凸函数的梯度的图像上的耦合 $\gamma\in\Gamma_{\mu,\nu}$ 都必定最优. 这一等价关系由下面的最优传输基本定理推出. 事实上，这一定理还包含原问题 (W_2^2) 与其对偶问题 (D-W_2^2) 之间的强对偶这一基本结果，它是建立上述等价关系的关键.

定理 1.14 (最优传输基本定理). 设 $\mu,\nu\in\mathcal{P}_2(\mathbb{R}^d)$ 为两个概率测度，且 μ 有密度；设 $X\sim\mu$. 则下列陈述等价：

(i) $\bar\gamma\in\Gamma_{\mu,\nu}$ 是最优耦合，即

$$\int\|x-y\|^2\,\bar\gamma(dx,dy)=W_2^2(\mu,\nu).$$

(ii) 存在正常凸函数（*proper convex function*）φ，使得 $(X,\nabla\varphi(X))\sim\bar\gamma\in\Gamma_{\mu,\nu}$.

(iii) (W_2^2) 与 (D-W_2^2) 之间成立强对偶：

$$\int\|x-y\|^2\,\bar\gamma(dx,dy)=\sup_{\substack{f\in L^1(\mu),\ g\in L^1(\nu)\\ f(x)+g(y)\leq\|x-y\|^2}}\left\{\int f\,d\mu+\int g\,d\nu\right\}.$$

此外，上述上确界由下列函数取得：

$$\bar f(x):=\|x\|^2-2\varphi(x),\qquad \bar g(y):=\|y\|^2-2\varphi^*(y).$$

证明. 我们已经在节 1.4中证明了 (i) $\Longrightarrow$ (ii)，所以只需证明 (ii) $\Longrightarrow$ (iii) 以及 (iii) $\Longrightarrow$ (i).

先证明 (ii) $\Longrightarrow$ (iii). 为此注意到，对 μ 几乎处处的 x，

$$\|x-\nabla\varphi(x)\|^2=\|x\|^2+\|\nabla\varphi(x)\|^2-2\langle x,\nabla\varphi(x)\rangle.$$

此外，φ 的凸共轭 φ^* 对 μ 几乎处处的 x 满足

$$\varphi(x)+\varphi^*(\nabla\varphi(x))=\langle\nabla\varphi(x),x\rangle.$$

这是 Fenchel–Young 不等式（原书定理 A.6）的取等条件. 以上两式给出

$$\begin{aligned}\|x-\nabla\varphi(x)\|^2=&\underbrace{\|x\|^2-2\varphi(x)}_{\bar f(x)}\\&+\underbrace{\|\nabla\varphi(x)\|^2-2\varphi^*(\nabla\varphi(x))}_{\bar g(\nabla\varphi(x))}.\end{aligned}$$

对 μ 积分可得

$$\begin{aligned}\int\|x-y\|^2\,\bar\gamma(dx,dy)&=\int\|x-\nabla\varphi(x)\|^2\,\mu(dx)\\&=\int\bar f(x)\,\mu(dx)+\int\bar g(\nabla\varphi(x))\,\mu(dx)\\&=\int\bar f(x)\,\mu(dx)+\int\bar g(y)\,\nu(dy).\end{aligned}\tag{1.18}$$

现在检验函数对 $(\bar f,\bar g)$ 满足 (D-W_2^2) 的约束. 由 Fenchel–Young 不等式（原书定理 A.6），对任意 $x,y\in\mathbb{R}^d$，

$$\begin{aligned}\bar f(x)+\bar g(y)&=\|x\|^2+\|y\|^2-2\big(\varphi(x)+\varphi^*(y)\big)\\&\le\|x\|^2+\|y\|^2-2\langle x,y\rangle=\|x-y\|^2.\end{aligned}\tag{1.19}$$

为检验可积性，注意根据凸共轭的定义，$\varphi=\varphi^{**}$ 与 φ^* 都有仿射函数作为下界. 因此，由于 $\mu,\nu\in\mathcal{P}_2(\mathbb{R}^d)$，有 $f_+\in L^1(\mu)$ 和 $g_+\in L^1(\nu)$. 此外，(1.18) 给出 $\int f\,d\mu+\int g\,d\nu\ge 0$，所以 $\int f\,d\mu>-\infty$ 且 $\int g\,d\nu>-\infty$. 于是

$$\int|f|\,d\mu=2\int f_+\,d\mu-\int f\,d\mu<\infty,$$

即 $f\in L^1(\mu)$；类似地，$g\in L^1(\nu)$. 这就证明了 (ii) $\Longrightarrow$ (iii).

接下来证明 (iii) $\Longrightarrow$ (i). 由(1.18)，对任意 $\gamma\in\Gamma_{\mu,\nu}$，有

$$\begin{aligned}\int\|x-y\|^2\,\bar\gamma(dx,dy)&=\int\bar f\,d\mu+\int\bar g\,d\nu\\&=\int\big(\bar f(x)+\bar g(y)\big)\,\gamma(dx,dy)\\&\le\int\|x-y\|^2\,\gamma(dx,dy),\end{aligned}$$

最后一步不等式使用了(1.19). 因而 $\bar\gamma$ 为最优耦合，(i) 得证. □

即使 μ 没有密度，这一定理的某些推论仍然成立. 特别地，利用这些工具可以证明强对偶仍然成立，而且命题 1.11的逆命题也成立：对于任意两个测度 $\mu,\nu\in\mathcal{P}_2(\mathbb{R}^d)$，若 $\gamma\in\Gamma_{\mu,\nu}$ 支撑在一个循环单调集上，则它必定是最优耦合（例如见 [17]）.

定理 1.14 中出现的最优函数 f 和 g 在后文中起着核心作用.

定义 1.15 (Kantorovich 势). *在 Kantorovich 对偶问题 (D-W_2^2) 中实现最优值的函数*

$$\bar f(x)=\|x\|^2-2\varphi(x),\qquad \bar g(y)=\|y\|^2-2\varphi^*(y)$$

称为测度对 (μ,ν) 的 Kantorovich 势（Kantorovich potentials）.

虽然 (D-W_2^2) 的解先验地只在几乎处处的意义下定义，$\bar f$ 和 $\bar g$ 却是在整个 $\mathbb{R}^d$ 上处处定义的实实在在的函数. 注意，由 (D-W_2^2) 的对称性和 Kantorovich 势的形式，很容易验证：若 ν 有密度，则 $\nabla\varphi^*$ 是从 ν 到 μ 的最优传输映射.

1.5.4 改进的 Brenier 定理

借助基本定理，可以给出一个常用的 Brenier 定理的改进版本.

定理 1.16 (改进的 Brenier 定理). *设 $\mu,\nu\in\mathcal{P}_2(\mathbb{R}^d)$ 为两个概率测度，μ 有密度，并设 $X\sim\mu$. 那么存在一个凸函数 $\varphi:\mathbb{R}^d\to\mathbb{R}$，使得 $(X,\nabla\varphi(X))\sim\bar\gamma\in\Gamma_{\mu,\nu}$，且 $\bar\gamma$ 是 (W_2^2) 的最优耦合：*

$$\begin{aligned}\int\|x-y\|^2\,\bar\gamma(dx,dy)&=\min_{\gamma\in\Gamma_{\mu,\nu}}\int\|x-y\|^2\,\gamma(dx,dy)\\&=W_2^2(\mu,\nu).\end{aligned}$$

此外，$\nabla\varphi$ 在如下意义下唯一：若存在凸函数 ψ 使得 $\nabla\psi(X)\sim\nu$，则几乎必然有 $\nabla\psi(X)=\nabla\varphi(X)$.

特别地，对于任意凸函数 ψ，只要形如 $(X,\nabla\psi(X))\sim\gamma$ 的耦合 $\gamma\in\Gamma_{\mu,\nu}$ 是一个有效耦合，它就必定是 μ 与 ν 之间唯一的最优耦合.

证明. 我们已经在上一小节证明了 φ 的存在性，现在需要证明 $\nabla\varphi$ 的唯一性.

事实上，只要每个最优耦合都由一个传输映射诱导，这个传输映射（从而最优耦合）就必定唯一.

为说明这一点，设 γ_1 和 γ_2 是两个最优耦合，分别由传输映射 T_1 和 T_2 诱导：

$$\gamma_1(Y=T_1(X))=1,\qquad \gamma_2(Y=T_2(X))=1.$$

考虑耦合 $\bar\gamma=(\gamma_1+\gamma_2)/2\in\Gamma_{\mu,\nu}$. 它也是最优的，因为

$$\begin{aligned}\int\|x-y\|^2\,\bar\gamma(dx,dy)&=\frac12\int\|x-y\|^2\,\gamma_1(dx,dy)+\frac12\int\|x-y\|^2\,\gamma_2(dx,dy)\\&=W_2^2(\mu,\nu).\end{aligned}$$

特别地，由 Brenier 定理，$\bar{\gamma}$ 也由某个传输映射 T 诱导（它恰好是某个凸函数的梯度，但这里并不需要这一事实）. 因而，若 $(X,Y)\sim\bar{\gamma}$，则给定 X 时 Y 的条件分布必为 Dirac 测度 $\delta_{T(X)}$. 但根据构造，这个条件分布是两个 Dirac 测度的混合 $(\delta_{T_1(X)}+\delta_{T_2(X)})/2$，二者只有在几乎必然有 $T_1(X)=T_2(X)=T(X)$ 时才可能相同.

因此，若存在凸函数 ψ，使得 $\nabla\psi(X)\sim\nu$，则由定理 1.14，满足 $(X,\nabla\psi(X))\sim\gamma\in\Gamma_{\mu,\nu}$ 的 γ 必为最优耦合；由上述讨论，几乎处处有 $\nabla\psi(X)=\nabla\varphi(X)$.

最后，定理 1.14 中 (ii) $\Longleftrightarrow$ (i) 这一等价关系意味着，最优耦合支撑在某个凸函数的梯度的图像上；由上述论证，这个梯度必定唯一，从而得到定理的最后一个结论. □

改进的 Brenier 定理非常有用，因为它刻画了传输映射的最优性：若某个传输映射是凸函数的梯度，则它既最优又唯一！我们称这个映射为 Brenier 映射（Brenier map）. 利用定理 1.16，可以在最优传输问题的两种基本情形——一维情形和高斯情形——中刻画最优传输映射.

例 1.17 (一维最优传输). *回顾随机变量 X 的累积分布函数（cumulative distribution function，CDF）F，它是映射 $t\mapsto\mathbb{P}(X\le t)$.*

命题 1.18. *设 $\mu,\nu\in\mathcal{P}_2(\mathbb{R})$ 为两个一元分布，其累积分布函数分别为 F_μ 和 F_ν，且 μ 有密度. 则*

$$W_2^2(\mu,\nu)=\int_0^1|F_\mu^\dagger(u)-F_\nu^\dagger(u)|^2\,du,$$

且 μ 与 ν 之间的最优耦合由 Brenier 映射 $F_\nu^\dagger\circ F_\mu$ 诱导.

证明. 由于 μ 有密度，$F_\mu\circ F_\mu^\dagger=\mathrm{id}$. 设 $U\sim\mathrm{Unif}([0,1])$ 为均匀随机变量，并定义 $X=F_\mu^\dagger(U)$、$Y=F_\nu^\dagger(U)$，于是 $X\sim\mu$、$Y\sim\nu$. 接着注意到 $Y=F_\nu^\dagger\circ F_\mu(X)$，并且 $F_\nu^\dagger\circ F_\mu$ 是递增函数. 根据定理 1.16，这就给出了 μ 与 ν 之间唯一的最优耦合. □

这一恒等式的几何推论是：赋予 2-Wasserstein 距离的度量空间 $\mathcal{P}_2(\mathbb{R})$ 是平坦的；原书第 7 章将进一步探讨这一点. 的确，映射 $\mu\mapsto F_\mu^\dagger$ 将 $(\mathcal{P}_2(\mathbb{R}),W_2)$ 等距嵌入了平坦的 Hilbert 空间 $L^2([0,1])$.

例 1.19 (高斯最优传输). *还可以利用改进的 Brenier 定理推导两个高斯测度之间的最优传输映射. 设 $m_1,m_2\in\mathbb{R}^d$，Σ_1,Σ_2 为 $d\times d$ 正定矩阵，并设 $\mu_1=\mathcal{N}(m_1,\Sigma_1)$、$\mu_2=\mathcal{N}(m_2,\Sigma_2)$.*

回顾仿射映射保持高斯性：若 $X_1\sim\mu_1$ 且 $T(x)=Ax+b$，其中 $A\in\mathbb{R}^{d\times d}$、$b\in\mathbb{R}^d$，则 $T(X_1)$ 也是高斯的. 为计算 $T(X_1)$ 的分布，只需计算其均值和协方差，可得

$$\mathbb{E}T(X_1)=Am_1+b,\qquad \operatorname{cov}T(X_1)=A\Sigma_1A^{\mathsf{T}}.$$

因此，猜测从 μ_1 到 μ_2 的最优传输映射为仿射映射是合理的，并且可以利用 *Brenier* 定理 *1.16* 来验证. 为此，需要 $Am_1 + b = m_2$ 和 $A\Sigma_1 A^{\mathsf{T}} = \Sigma_2$，它们表示约束 $T_{\#}\mu_1 = \mu_2$. 还需要 T 是某个凸函数的梯度. 若取

$$\varphi(x) = \frac{1}{2}\langle x, Ax\rangle + \langle b, x\rangle,$$

则 $\nabla\varphi(x) = \frac{1}{2}(A + A^{\mathsf{T}})x + b$，而 $A + A^{\mathsf{T}} \succeq 0$ 保证 φ 为凸函数. 由此可知，只要 A 对称正定，$T = \nabla\varphi$ 就是凸函数的梯度，因而最优.

如何选择 A 和 b，才能同时满足推前约束和 A 的半正定（*positive semidefinite*, *PSD*）约束？最朴素的选择 $A = \Sigma_1^{-1/2}\Sigma_2^{1/2}$ 在 Σ_1 和 Σ_2 可交换时有效，但一般而言，这样的 A 甚至不是对称的. 要找到一个满足要求的半正定 A，需要一点巧思，但可以按如下方式做到. 从 A 半正定且满足 $A\Sigma_1 A = \Sigma_2$ 出发，将 $\Sigma_1^{1/2} A \Sigma_1^{1/2}$ 平方，得到

$$\begin{aligned}(\Sigma_1^{1/2} A \Sigma_1^{1/2})^2 &= \Sigma_1^{1/2} A \Sigma_1 A \Sigma_1^{1/2} \\ &= \Sigma_1^{1/2} \Sigma_2 \Sigma_1^{1/2}.\end{aligned}$$

取平方根并求解，得到

$$A = \Sigma_1^{-1/2}(\Sigma_1^{1/2}\Sigma_2\Sigma_1^{1/2})^{1/2}\Sigma_1^{-1/2}.$$

可见这就是我们寻找的矩阵 A. 利用另一个约束 $Am_1 + b = m_2$，得到

$$T(x) = \Sigma_1^{-1/2}(\Sigma_1^{1/2}\Sigma_2\Sigma_1^{1/2})^{1/2}\Sigma_1^{-1/2}(x - m_1) + m_2.$$

由定理 *1.16*，这就是从 μ_1 到 μ_2 唯一的最优传输映射. 此外，将它代入 *Wasserstein* 距离的定义可得（留作习题!）

$$\begin{aligned}W_2^2(\mu_1, \mu_2) = \|m_1 - m_2\|^2 \\ + \operatorname{tr}\left[\Sigma_1 + \Sigma_2 - 2(\Sigma_1^{1/2}\Sigma_2\Sigma_1^{1/2})^{1/2}\right].\end{aligned} \tag{1.20}$$

1.6 $p = 1$ 时的对偶

对于 1-Wasserstein 度量，对偶具有十分简洁的形式. 大多数教材将这一结果视为一般代价 c 的最优传输强对偶的一个特例来推导；这需要使用一些工具，将定理 1.14推广到二次代价 $c(x, y) = \|x - y\|^2$ 之外. 这些工具包括循环单调性和 Legendre 变换的推广概念，建议读者熟悉它们（简要介绍见节 1.7）. 将这些结果用于 p-Wasserstein 距离，就得到以下定理；证明可参见 [281, 第 3.1.1 小节].

定理 1.20. 固定 $p \geq 1$，设 $\mu, \nu \in \mathcal{P}_p(\mathbb{R}^d)$ 为两个概率测度. 则有

$$W_p^p(\mu, \nu) = \sup_{\substack{f \in L^1(\mu),\ g \in L^1(\nu) \\ f(x) + g(y) \leq \|x - y\|^p}} \left\{ \int f \, d\mu + \int g \, d\nu \right\}. \tag{1.21}$$

当 $p=1$ 时，可以化简这一结果，消去一个对偶函数.

定理 1.21. *设 $\mu,\nu\in\mathcal{P}_1(\mathbb{R}^d)$ 为两个概率测度. 则有*

$$W_1(\mu,\nu)=\sup_{f\in\mathrm{Lip}_1}\left\{\int f\,d\mu-\int f\,d\nu\right\},\tag{1.22}$$

其中 Lip_1 是所有 1-Lipschitz 函数组成的集合.

在证明这一定理之前，先看看 Lipschitz 函数是如何出现的. 回顾节 1.5.2中的半对偶，它也消去了一个对偶函数. 特别地，当 $p=1$ 时，可以将(1.21)中的函数 g 替换为 c-变换

$$f^c(y)=\inf_{x\in\mathbb{R}^d}\{\|x-y\|-f(x)\}.$$

有如下引理.

引理 1.22. *对于 $c(x,y)=\|x-y\|$，函数 $g:\mathbb{R}^d\to\mathbb{R}$ 是某个 c-变换 $g=f^c$，当且仅当它是 1-Lipschitz 函数. 此外，任意 1-Lipschitz 函数都满足 $g^c=-g$.*

证明. 写成

$$g(y)=f^c(y)=\inf_{x\in\mathbb{R}^d}\{\|x-y\|-f(x)\}.$$

对任意 x，由反三角不等式，函数 $y\mapsto\|x-y\|-f(x)$ 显然为 1-Lipschitz 函数. 因为 1-Lipschitz 函数的集合对取下确界封闭，所以 g 也是 1-Lipschitz 函数.

为证明逆命题，设 g 为 1-Lipschitz 函数，于是对任意 $x,y\in\mathbb{R}^d$，

$$g(y)\le\|x-y\|+g(x).$$

对 x 取下确界，得到 $g\le(-g)^c$. 此外，

$$(-g)^c(y)=\inf_{x\in\mathbb{R}^d}\{\|x-y\|+g(x)\}\le g(y),$$

其中最后一步不等式取了 $y=x$.

我们已经证明 $(-g)^c=g$，特别地，g 必为一个 c-变换，即 $-g$ 的 c-变换. 引理的第二个结论由如下事实得到：若 g 为 1-Lipschitz 函数，则 $-g$ 也是. □

现在可以证明定理 1.21了.

定理 1.21的证明. 由节 1.5.2中的论证，(1.21) 等于以下半对偶：

$$\sup_{f\in L^1(\mu)}\left\{\int f\,d\mu+\int f^c\,d\nu\right\}.$$

还可以继续优化对偶势，得到

$$\sup_{f\in L^1(\mu)}\left\{\int f^{cc}\,d\mu+\int (f^{cc})^c\,d\nu\right\}.$$

由引理 1.22，集合

$$\{f^{cc} : f \in L^1(\mu)\}$$

只包含 1-Lipschitz 函数. 此外，由于 $\mu \in \mathcal{P}_1(\mathbb{R}^d)$，任意 1-Lipschitz 函数均关于 μ 可积:

$$\begin{aligned}\int |f|\, d\mu &\le \int |f(x) - f(y)|\, \mu(dx) + |f(y)| \\ &\le \int \|x - y\|\, \mu(dx) + |f(y)| < \infty,\end{aligned}$$

所以 $f \in L^1(\mu)$. 因此，我们已经证明

$$\begin{aligned}W_1(\mu,\nu) &= \sup_{f\in \mathrm{Lip}_1} \left\{ \int f\, d\mu + \int f^c\, d\nu \right\} \\ &= \sup_{f\in \mathrm{Lip}_1} \left\{ \int f\, d\mu - \int f\, d\nu \right\},\end{aligned} \tag{1.23}$$

定理 1.21得证. □

1.7 讨论

节 1.1. 历史文献综述可参见 [315].

节 1.2. Villani[317] 指出，通行的 “Wasserstein 距离” 这一名称 “很值得质疑”：尽管 Dobrushin[114] 将这些距离归于 Leonid Vasershtein，但 Vasershtein 并非它们的创始人. 不过，这个名称已经沿用下来.

命题 1.5取自论文 [271]，该文还给出了一个逆命题. 所谓的传输不等式（transport inequality）蕴含了 “信息散度”（例如全变差、Kullback–Leibler 散度和卡方散度）与最优传输距离之间的进一步比较；这又与测度集中这一更广泛的文献领域相联系，参见例如 [46] 以及 [317, 第 22 章].

节 1.3. 如习题 8所示，定理 1.7和命题 1.18中的单调耦合，对于任何由 $x - y$ 的严格凸函数给出的成本函数也都是最优的，参见 [281, 第 2.2 节].

节 1.4. Chernozhukov 等人 [75] 首次利用 Brenier 定理，为 $\nu \in \mathcal{P}_2(\mathbb{R}^d)$ 定义多元分位数（multivariate quantile）；Hallin[158] 又将此定义推广到可能没有二阶矩的 ν. 除了数学上的优美之外，多元分位数的这一定义对于非参数检验也有重要意义 [103, 147].

Rockafellar 定理来自 [273]. 命题 1.11的证明来自 [138].

节 1.5. 我们通过明确给出对偶间隙为零的对偶势，推导出了强对偶性；这些势来自最优耦合具有循环单调支撑这一刻画. 也可以直接诉诸抽象的极小极大原理来证明强对偶性，参见 [315, 第 1.1 节].

节 1.5中的许多论证都可以推广到一般连续成本 $c : \mathcal{X} \times \mathcal{Y} \to \mathbb{R}$：函数 $f : \mathcal{X} \to \mathbb{R}$ 的 c-共轭（c-conjugate）为

$$f^c(y) := \inf_{x\in\mathcal{X}} \{c(x,y) - f(x)\},$$

同样，函数 $g : \mathcal{Y} \to \mathbb{R}$ 的 c-共轭为

$$g^c(x) := \inf_{y \in \mathcal{Y}} \{c(x, y) - g(y)\}.$$

如果存在函数 g 使得 $f = g^c$，就称 f 为 c-凹的（c-concave）. 等式(1.17)仍然成立，其值等于最优传输值，即强对偶性成立. 任何最优传输计划都支撑在一个 c-循环单调集上；这一定义与(1.12)相同，只需将二次成本换成 c. 进而，c-循环单调集可用 c-次微分来刻画：c-凹函数 $f = g^c$ 的 c-次微分是满足 $f(x) + g(y) = c(x, y)$ 的点对 (x, y) 所成的集合. 然而，Brenier 定理并不容易如此推广，因为还需要额外条件来保证 c-次微分的单值性. 例如，若 $c(x, y) = h(x - y)$，其中 h 是严格凸函数，那么唯一的最优传输映射存在，但它未必是凸函数的梯度，参见 [281, 定理 1.17].

节 1.6. W_1 的对偶公式是一个经典结果，与有界 Lipschitz 度量（bounded Lipschitz metric）[123] 密切相关；后者可以推广为符号测度上的范数. 如原书第 2.8.1 节所讨论的那样，这个公式把 W_1 表示为积分概率度量（integral probability metric）.

1.8 习题

习题 1. 设 $A \subseteq \mathbb{R} \times \mathbb{R}$ 是单调的：

$$\forall (x, y), (x', y') \in A, \qquad x < x' \implies y < y'.$$

为简单起见，假设 A 包含在某个函数的图像中. 证明 A 是循环单调的.

习题 2. 设随机变量 $X \in \mathbb{R}$ 具有一个支撑为整条实线的密度. 设 f, g 为两个单调递增函数，且 $f(X)$ 与 $g(X)$ 同分布. 则 $f = g$ 几乎处处成立.

习题 3. 设 $m_1, m_2 \in \mathbb{R}^d$，$\Sigma_1, \Sigma_2$ 为正定的 $d \times d$ 矩阵. 令 $\mu_1 = \mathcal{N}(m_1, \Sigma_1)$、$\mu_2 = \mathcal{N}(m_2, \Sigma_2)$.

(a) 验证公式(1.20).

(b) 通过一个次优耦合，证明下面的简单上界：

$$W_2^2(\mu_1, \mu_2) \le \|m_1 - m_2\|^2 + \|\Sigma_1^{1/2} - \Sigma_2^{1/2}\|_{\mathrm{HS}}^2,$$

其中 $\|M_1 - M_2\|_{\mathrm{HS}}^2 := \mathrm{tr}((M_1 - M_2)^{\mathsf{T}}(M_1 - M_2))$. 证明当 Σ_1 与 Σ_2 可交换时等号成立.

(c) 证明：若 ν_1, ν_2 分别为均值 m_1, m_2、协方差矩阵 Σ_1, Σ_2 的概率测度，则

$$W_2(\nu_1, \nu_2) \ge W_2(\mu_1, \mu_2).$$

提示：从 μ_1 到 μ_2 的最优传输问题，其最优对偶势是什么？

习题 4. *(a)* 设 X, Y 是 $\mathbb{R}^d$ 中的随机向量. 证明

$$W_2^2\big(\mathrm{law}(X), \mathrm{law}(Y)\big) = \|\mathbb{E}X - \mathbb{E}Y\|^2 + W_2^2\big(\mathrm{law}(X - \mathbb{E}X), \mathrm{law}(Y - \mathbb{E}Y)\big).$$

由于这个等式，在使用 W_2 距离时，通常只需考虑中心化随机变量.

(b) 设 $X, Y_1, \dots, Y_k$ 为 $\mathbb{R}^d$ 中的随机向量，且 $\lambda_1, \dots, \lambda_k \geq 0$. 假设对每个 $i = 1, \dots, k$，X 与 Y_i 都构成最优耦合. 证明 X 与 $\sum_{i=1}^k \lambda_i Y_i$ 构成最优耦合.

习题 5. 设 ν 具有相对于 *Lebesgue* 测度的密度. 证明 $W_2^2(\cdot, \nu)$ 严格凸；也就是说，若 $\mu_0, \mu_1 \in \mathcal{P}_2(\mathbb{R}^d)$ 互不相同且 $t \in (0,1)$，则

$$W_2^2\big((1-t)\mu_0 + t\mu_1, \nu\big) < (1-t)W_2^2(\mu_0, \nu) + tW_2^2(\mu_1, \nu). \tag{1.24}$$

提示：先证明将(1.24)中的 $<$ 换成 $\leq$ 后不等式成立. 然后，假设(1.24)不成立，证明 $(1-t)\mu_0 + t\mu_1$ 与 ν 之间存在一个并非由传输映射诱导的最优传输计划，从而与 *Brenier* 定理矛盾.

习题 6. 考虑测度 $\mu = \frac{1}{2}\mathcal{N}(-m, 1) + \frac{1}{2}\mathcal{N}(+m, 1)$ 与 $\nu = \frac{1}{4}\mathcal{N}(-m, 1) + \frac{3}{4}\mathcal{N}(+m, 1)$，其中 $m > 0$. 证明 $W_2(\mu, \nu) \asymp m$.

提示：本题的要点在于：计算从 μ 到 ν 的最优传输映射很麻烦，但得到良好的上下界并不难. 对于下界，证明并利用如下事实：对任意 *1-Lipschitz* 函数 $f : \mathbb{R} \to \mathbb{R}$，都有 $\mathbb{E}_\mu f - \mathbb{E}_\nu f \leq W_1(\mu, \nu) \leq W_2(\mu, \nu)$. 对于上界，给出 μ 与 ν 的一个耦合.

习题 7. 回顾两个概率测度 μ, ν 之间的卡方散度（*chi-squared divergence*）定义为

$$\chi^2(\mu \,\|\, \nu) = \int \left(\frac{d\mu}{d\nu} - 1\right)^2 d\nu.$$

证明：当 ν 的方差为 *1* 时，

$$W_1(\mu, \nu) \leq \sqrt{\chi^2(\mu \,\|\, \nu)}.$$

习题 8. 设 $c : \mathbb{R} \to \mathbb{R}$ 严格凸，并考虑 $\mathbb{R}$ 上成本函数为 $(x, y) \mapsto c(x - y)$ 的最优传输. 例如，当 $c(z) = |z|^p$ 且 $p > 1$ 时，便得到 W_p^p. 本题要证明命题 *1.18*给出的耦合 $\bar{\gamma}$ 对于所有这类成本都普遍最优. 背景见节 *1.7*.

(a) 证明对任意 $a, b \in \mathbb{R}$，$\bar{\gamma}((-\infty, a] \times (-\infty, b]) = F_\mu(a) \wedge F_\nu(b)$.

(b) 证明 $\bar{\gamma}$ 是 μ 与 ν 之间满足下式的唯一耦合：

$$\forall\, (x, y), (x', y') \in \operatorname{supp} \bar{\gamma}, \qquad x < x' \implies y \leq y'. \tag{1.25}$$

提示：考虑集合 $A = (-\infty, a] \times (b, \infty)$ 和 $B = (a, \infty) \times (-\infty, b]$. 证明任何满足(1.25)的耦合都必须赋予这两个集合之一零测度. 利用这一点证明，任何满足(1.25)的耦合 γ 都必须与 $\bar{\gamma}$ 相同.

(c) 设 $(x,y),(x',y') \in \operatorname{supp}\gamma$，其中 γ 是 μ,ν 之间关于上述成本 c 的最优传输计划. 由 $\operatorname{supp}\gamma$ 的 c-循环单调性，

$$c(x-y)+c(x'-y') \le c(x-y')+c(x'-y).$$

证明：若 $x<x'$，则 $y \le y'$；因此 $\gamma=\bar{\gamma}$.

提示：使用反证法. 若结论不成立，则 $u := x-y'$ 和 $v := x'-y$ 都位于 $w := x-y$ 与 $w' := x'-y'$ 之间. 将 u,v 表示为 w,w' 的凸组合，并应用 c 的严格凸性.

(d) 推出最优成本等于 $\mathbb{E}c(F_\mu^\dagger(U)-F_\nu^\dagger(U))$，其中 $U \sim \mathrm{Unif}([0,1])$.

习题 9. 给定同一空间 S 上的两个概率测度 μ,ν，定义它们之间的全变差距离（*total variation distance*）为

$$d_{\mathrm{TV}}(\mu,\nu)=\sup_{A\subseteq S}|\mu(A)-\nu(A)|,$$

其中上确界遍历所有可测子集. 证明全变差距离也等于以下各式. （提示：考虑定理 *1.6*中的耦合.）

(a) 若 f,g 分别为 μ,ν 相对于它们的某个共同控制测度 λ（例如 $\lambda=\mu+\nu$）的密度，则[2]

$$d_{\mathrm{TV}}(\mu,\nu)=\frac{1}{2}\int|f-g|\,d\lambda=1-\int f\wedge g\,d\lambda=\mu(f\ge g).$$

(b) $d_{\mathrm{TV}}(\mu,\nu)=\inf\mathbb{P}(X\neq Y)$，其中下确界遍历 μ,ν 的所有耦合 (X,Y).

(c) $d_{\mathrm{TV}}(\mu,\nu)=\sup\{\int h\,d(\mu-\nu)\mid h:S\to[0,1]\}$. 将此式与定理 *1.21*的 W_1 对偶性作比较.

习题 10. 设 $\mu,\nu\in\mathcal{P}_2(\mathbb{R}^d)$ 具有相对于 *Lebesgue* 测度的密度. 证明：若 $\nabla\varphi$ 是从 μ 到 ν 的最优传输映射，则 $\nabla\varphi^*$ 是从 ν 到 μ 的最优传输映射. （参见原书附录 *A*.）将此事实用于两个高斯分布之间的最优传输映射，并找出一个非平凡的矩阵恒等式.

[2]译注：本行按原书印刷 36 页照录，末项存在疑误；具体说明见随附核验记录.

参考文献（本章引用）

[17] Ambrosio, L., Gigli, N.: A user' s guide to optimal transport. In: Modelling and Optimisation of Flows on Networks. Lecture Notes in Mathematics, vol. 2062, pp. 1–155. Springer, Heidelberg (2013).

[46] Bolley, F., Villani, C.: Weighted Csiszár–Kullback–Pinsker inequalities and applications to transportation inequalities. Ann. Fac. Sci. Toulouse Math. 14(3), 331–352 (2005).

[52] Boyd, S., Vandenberghe, L.: Convex Optimization. Cambridge University Press, Cambridge (2004).

[55] Brenier, Y.: Decomposition polaire et rearrangement monotone des champs de vecteurs. C. R. Acad. Sci. Paris Ser. I Math. 305, 805–808 (1987).

[75] Chernozhukov, V., Galichon, A., Hallin, M., Henry, M.: Monge–Kantorovich depth, quantiles, ranks and signs. Ann. Stat. 45(1), 223–256 (2017).

[103] Deb, N., Sen, B.: Multivariate rank-based distribution-free nonparametric testing using measure transportation. J. Am. Stat. Assoc. 118(541), 192–207 (2023).

[114] Dobrushin, R.L.: Prescribing a system of random variables by conditional distributions. Theory Probab. Appl. 15(3), 458–486 (1970).

[123] Dudley, R.M.: Real Analysis and Probability. Cambridge Studies in Advanced Mathematics, vol. 74. Cambridge University Press, Cambridge (2002). Revised reprint of the 1989 original.

[138] Gangbo, W., McCann, R.J.: The geometry of optimal transportation. Acta Math. 177(2), 113–161 (1996).

[147] Ghosal, P., Sen, B.: Multivariate ranks and quantiles using optimal transport: consistency, rates and nonparametric testing. Ann. Stat. 50(2), 1012–1037 (2022).

[158] Hallin, M.: On distribution and quantile functions, ranks and signs in $\mathbb{R}^d$. Working Papers ECARES 2017-34, ULB –Universite Libre de Bruxelles (2017).

[159] Hallin, M.: Measure transportation and statistical decision theory. Annu. Rev. Stat. Appl. 9, 401–424 (2022).

[160] Hallin, M., del Barrio, E., Cuesta-Albertos, J., Matrán, C.: Distribution and quantile functions, ranks and signs in dimension d: a measure transportation approach. Ann. Stat. 49(2), 1139–1165 (2021).

[173] Kantorovich, L.V.: On the translocation of masses. Dokl. Akad. Nauk SSSR 37(7–8), 227–229 (1942).

[231] Monge, G.: Mémoire sur la théorie des déblais et des remblais. Mém. de l' Ac. R. des Sc. 666–704 (1781).

[271] Rigollet, P., Niles-Weed, J.: Uncoupled isotonic regression via minimum Wasserstein deconvolution. Inf. Infer. 8(4), 691–717 (2019).

[273] Rockafellar, R.T.: Characterization of the subdifferentials of convex functions. Pac. J. Math. 17, 497–510 (1966).

[281] Santambrogio, F.: Optimal Transport for Applied Mathematicians. Progress in Nonlinear Differential Equations and Their Applications, vol. 87. Birkhäuser, Cham (2015). Calculus of variations, PDEs, and modeling.

[302] Tsybakov, A.B.: Introduction to Nonparametric Estimation. Springer Series in Statistics. Springer, New York (2009). Revised and extended from the 2004 French original, Translated by Vladimir Zaiats.

[314] Vershynin, R.: High-Dimensional Probability. Cambridge Series in Statistical and Probabilistic Mathematics, vol. 47. Cambridge University Press, Cambridge (2018). An introduction with applications in data science, With a foreword by Sara van de Geer.

[315] Villani, C.: Topics in Optimal Transportation. Graduate Studies in Mathematics, vol. 58. American Mathematical Society, Providence (2003).

[317] Villani, C.: Optimal Transport. Grundlehren der Mathematischen Wissenschaften [Fundamental Principles of Mathematical Sciences], vol. 338. Springer, Berlin (2009). Old and new.